



青岛大学
QINGDAO UNIVERSITY

本科毕业论文

题 目： LSSeg 与 SAM-LoRA 级联的医学线状结
 构图像分割方法研究

学 院： 计算机科学技术学院

专 业： 计算机科学与技术

姓 名： 王浩

指导教师： 赵爱特

2026 年 5 月

LSSeg 与 SAM-LoRA 级联的医学线状结构图
像分割方法研究

**Research on a Medical Linear-Structure
Image Segmentation Method Based on the
Cascading of LSSeg and SAM-LoRA**

郑 重 声 明

本人呈交的学位论文（设计），是在指导教师的指导下，独立进行研究工作所取得的成果，所有数据、图片资料真实可靠。除文中已经注明引用的内容外，本学位论文（设计）的研究成果不包含他人享有著作权的内容。对本论文（设计）所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确的方式标明。本学位论文（设计）的知识产权归属于青岛大学。

本人签名：_____ 日期：_____

摘 要

血管、神经纤维等线状结构分割是微观生物学图像分析当中的重要任务，但目标通常具有尺度细小、分支复杂、边界模糊以及拓扑连续性要求高等特性。现有方法在开展结构保持、进行连通性恢复以及边界刻画等方面仍存不足。针对这些问题，开展了专用线状结构与大规模预训练分割模型的协同建模研究。

提出了一种基于 LSSeg 以及 SAM-LoRA 的级联分割框架。该方法借助前端网络生成稳定粗分割结果，同时把它构造成提示信息，去引导后端分支对细小血管、边缘分支以及局部模糊区域进行修正。

为提升提示有效性，设计了高召回提示策略，并且结合残差机制来整合粗细分割结果，同时在训练中引入分层学习率、参数高效微调以及渐进式策略，来实现模型适配能力以及训练稳定性的提高。

在多个公开数据集上开展了实验验证，同时从区域重叠、结构保持以及边界误差等方面对方法进行评估。结果表明，该方法在 AP、Dice、IoU、cIDice、ASSD 以及 95HD 等指标上整体优于基线模型，能更有效地去补全细小分支、进行局部连通性改善并且提高边界定位精度。研究表明，LSSeg 以及 SAM-LoRA 的级联方法对微观生物学图像线状结构分割具备较好应用价值。

关键词 医学图像分割 线状结构 LSSeg SAM-LoRA 级联架构

Abstract

The segmentation of linear structures such as blood vessels and nerve fibers is a crucial task in microscopic biomedical image analysis. However, these targets typically exhibit characteristics including minute scales, complex bifurcations, blurred boundaries, and high demands for topological continuity. Existing methods still demonstrate inadequacies in carrying out structure preservation, performing connectivity restoration, and delineating boundaries. To address these issues, research was conducted on the collaborative modeling of dedicated linear structure models and large-scale pre-trained segmentation models.

A cascade segmentation framework based on LSSeg and SAM-LoRA is proposed. This method utilizes a front-end network to generate stable coarse segmentation results, which are simultaneously formulated as prompt information to guide the back-end branch in carrying out modifications on minute vessels, marginal branches, and locally blurred regions.

To enhance the effectiveness of the prompts, a high-recall prompting strategy was designed, and a residual mechanism was combined to integrate the coarse and fine segmentation results. Concurrently, hierarchical learning rates, parameter-efficient fine-tuning, and progressive strategies were introduced during the training process to achieve improvements in model

adaptability and training stability.

Experimental validations were conducted on multiple public datasets, and the method was evaluated from the perspectives of regional overlap, structure preservation, and boundary error. The results demonstrate that this method generally outperforms baseline models across metrics including AP, Dice, IoU, cIDice, ASSD, and 95HD. It can more effectively accomplish the completion of minute branches, perform local connectivity improvements, and enhance boundary localization precision. The research indicates that the cascade approach of LSSeg and SAM-LoRA possesses excellent application value for linear structure segmentation in microscopic biomedical images.

Keywords: Medical image segmentation Line-like structure LSSeg
SAM-LoRA Cascaded architecture

目 录

第 1 章 绪 论	1
1.1 研究背景和意义	1
1.2 国内外研究现状	2
1.3 主要研究内容	3
1.4 章节安排	5
第 2 章 相关理论基础	7
2.1 图像分割基础理论	7
2.1.1 分割任务定义	7
2.1.2 分割任务分类	8
2.1.3 医学图像分割常用评价指标	11
2.2 视觉 TRANSFORMER 与 SAM 模型	11
2.2.1 Vision Transformer 基本原理	11
2.2.2 SAM 模型架构	12
2.3 参数高效微调技术	14
2.3.1 全量微调与参数高效微调对比	14
2.3.2 LoRA 原理	15
2.3.3 LoRA 在视觉模型中的应用	16
2.4 LSSEG 线状结构分割网络	17
第 3 章 LSSEG 与 SAM-LORA 级联架构设计	20
3.1 级联架构设计思想	20
3.1.1 “粗到细”分割策略	20
3.1.2 为何选择 LSSeg 与 SAM-LoRA 级联	21
3.2 LSSEG 粗分割模块设计	23
3.3 SAM-LoRA 精细分割模块设计	25
3.4 PROMPT 构造与优化策略	26
3.5 残差融合	28
3.6 模型训练策略	30
第 4 章 实验结果与分析	33

4.1 实验环境与数据集	33
4.2 评价指标	34
4.3 对比实验	35
4.4 结果分析	36
第五章 总结	40
谢 辞	42
参考文献	43

第1章 绪 论

1.1 研究背景和意义

随着显微成像、数字病理以及高分辨率生物学成像设备的快速发展，微观图像已成为了生命科学研究、疾病辅助诊断以及精准医疗当中的重要数据来源。在眼底血管分析、神经纤维追踪、细胞结构观察以及组织病理研究等场景里，研究人员愈发依靠图像分割技术去把目标结构从复杂背景中准确提取出来，以此支持后续的定量分析、病灶识别以及形态学测量工作。故而，去开展面向微观图像高精度分割方法的研究，不仅有明显的工程应用价值，同时具备重要的医学以及科研意义。

与自然图像相比，微观图像具备自身鲜明的特性。首先，目标结构通常细小、狭长且分支丰富，像视网膜血管、神经纤维以及微观管状结构往往只会占据图像当中的少量像素，但它的连通性、走向以及拓扑关系却会直接去影响分析结果。其次，微观图像极易受成像噪声、光照不均、低对比度以及局部模糊等因素影响，从而导致边界不清、弱小结构易断裂以及背景干扰较强。再次，不同样本之间在染色方式、成像设备以及分辨率上存在差异，同类目标在形态、尺度以及灰度分布上也可能表现出较强的不一致性。这些特性决定了微观图像分割不能简单去照搬通用的图像分割方法，而是需针对细粒度结构表达、连续性保持以及边界恢复去开展专门的设计。

在此过程当中，数据本身的重要性尤为突出。微观图像不仅是模型训练的基础，同时也是评价算法有效性以及推广能力的核心依据。高质量的数据集能反映出真实场景当中的结构复杂性以及样本差异性，从而为模型去学习关键特征提供一定支撑；而合理的数据划分、可靠的标注结果以及多维度的评价指标，则直接关系到实验结论是否可信。对于视网膜血管等线状结构任务而言，仅依靠单一区域重叠指标往往不足以全面去反映模型性能，还需结合结构连续性以及边界距离等指标，从数据层面去保证评价的完整性以及科学性。所以，充分认识微观图像数据价值，并且围绕数据特征设计分割方法以及实验方案，是开展此研究的基础前提。

鉴于上述现实需求以及任务特性，本文聚焦于微观图像当中的线状结构分割问题，提出 LSSeg 以及 SAM-LoRA 级联架构，目的在于在保持基线分割稳定性的基础上，引入预训练模型的细化能力，以此提升细小结构、分支区域以及复杂边界的分割精度。借助该模型，有望为视网膜血管等典型微观图像的自动分析提供更可靠的技术支撑，并且为医学图像智能处理方法的进一步发展提供一定参考。

1.2 国内外研究现状

近年来,深度学习在医学人工智能领域取得了快速发展,研究对象也从单一图像或者单一生理信号扩展到了书写轨迹、语音、运动轨迹以及医学图像等多种数据类型。以帕金森病辅助筛查研究为例,相关工作凭借增强神经网络、时空孪生网络、坐标注意力增强 Transformer、迁移学习网络以及双通道时序模型,去对患者的书写行为、语音特征以及运动轨迹开展自动识别与评估工作^[1-6]。这些研究虽然不直接属于图像分割任务,但它们说明,在医疗数据样本有限、噪声较强并且异常特征细微的条件下,注意力机制、Transformer 建模以及迁移学习策略能够有效地去提升模型的特征表达能力以及泛化性能。那么这一研究趋势,会为医学图像分割,特别是微观图像当中细粒度结构的识别以及建模提供重要的方法学启发。

在图像分割领域,早期方法主要依赖阈值分割、区域生长、边缘检测、形态学操作以及活动轮廓模型等传统技术。这类方法在图像对比度较高、背景较为简单时具备一定的效果,但它对人工规则以及先验知识的依赖较强,当去处理微观图像当中普遍存在的低对比度、噪声干扰、边界模糊以及目标尺度较小等问题时,往往难以去兼顾鲁棒性以及泛化性^[20]。随着深度学习的发展,Long 等提出的全卷积网络也就是 FCN,为端到端语义分割提供了通用框架^[7];Ronneberger 等提出的 U-Net 借助编码器、解码器以及跳跃连接相结合,显著提升了医学图像分割的定位能力以及细节恢复能力^[8];DeepLab 运用空洞卷积以及多尺度上下文建模进一步增强了复杂场景下的分割性能^[9];nnU-Net 则从自动配置角度证明了规范化训练流程、预处理以及后处理策略对医学图像分割性能的重要作用^[10]。这些研究奠定了当前医学图像分割方法的基础框架。

在此基础之上,国内外研究者进一步围绕注意力机制、多尺度特征融合以及 Transformer 建模开展了大量工作。Attention U-Net 借助在跳跃连接当中引入注意力门机制,提升了网络对目标区域的聚焦能力^[11];UNETR 把 Transformer 运用于编码阶段,以此增强全局依赖关系建模能力^[12];TransUNet 结合了卷积网络的局部特征提取优势以及 Transformer 的全局建模能力,进一步改善了医学图像当中复杂目标的分割效果^[13];Swin-Unet 则探索了纯 Transformer 架构在医学图像分割当中的可行性^[14]。总体来看,医学图像分割已经由单纯依靠卷积特征提取,发展为融合局部纹理、全局上下文以及注意力建模的综合框架。

对于视网膜血管、神经纤维以及细胞轴突等线状结构分割任务,研究重点则更多集中在微细分支保留、拓扑连续性维护以及边界精细恢复上。Shit 等提出的 clDice 强调了拓扑保持在管状结构分割当中的重要性,指出传统的 Dice 以及 IoU 等区域指标难以去全面反映线状结构的真实分割质量^[19]。Khandouzi 等对视网膜血

管分割方法开展了系统综述,认为血管粗细变化明显、背景复杂以及微细血管易断裂是该领域长期存在的关键难点^[20]。围绕这些问题,Hard Attention Net 借助强化对困难区域的响应去提升血管检测能力^[21],Densely Connected U-Net 运用密集连接来改善特征的复用以及传递^[22],MS-LSDNet 在结构检测以及骨架重连方面增强了分割结果的连通性^[23],LEA U-Net 则结合局部特征增强以及注意力机制去提升对微小血管的识别能力^[24]。这样可以看出,线状结构分割研究已经从单纯追求区域重叠精度,逐渐转向把区域、结构以及边界质量并重的发展方向。

近年来,以基础模型为代表的大规模预训练方法又为医学图像分割带来了新的研究热点。Kirillov 等提出的 SAM 凭借大规模数据预训练以及提示(即 prompt)驱动分割机制,在自然图像场景当中展现出了较强的泛化能力^[15]。然而,后续研究表明,医学图像在尺度分布、纹理特性、目标形态以及标注方式等方面与自然图像存在显著差异,因此 SAM 在医学场景当中的性能并不稳定^[16]。围绕这一问题,研究者开始尝试运用参数高效微调方法去提升它的医学适配能力,其中 Zhang 以及 Liu 提出的鉴于 LoRA 来开展的定制化 SAM 方案,展示了把大部分主干参数冻结、仅更新少量可训练参数即可实现高效迁移的可行性^[17];Medical SAM Adapter 则从适配器设计角度进一步增强了 SAM 对医学目标的表征能力^[18]。这说明,基础模型进入医学图像分割领域后,研究重点已经从“是否能够迁移”转向“如何结合任务先验去实现稳定适配”。

综合来看,国内外相关研究已经在医学图像分割、视网膜血管分割以及基础模型医学适配等方面取得了较多成果,但仍存在一些尚未充分解决的问题:一方面,通用分割网络在细小血管、弱边界以及复杂分支区域的表达能力仍然有限^[19];另一方面,基础模型虽然具有较强的先验知识,但它的医学适配通常依赖 prompt 设计、参数高效微调^[15]以及任务特定约束,尚难直接去替代专用分割模型。因此,探索一种既能保留专用线状结构分割模型稳定性,又能借助预训练模型细化能力的级联框架,仍然具备较强的研究意义。本文围绕 LSSeg 以及 SAM-LoRA 的协同建模展开研究,正是对这一问题的进一步探索。

1.3 主要研究内容

针对微观图像当中线状结构分割任务存在的细小目标易遗漏、分支连续性难保持、边界模糊区域难刻画以及基础模型难以直接适应医学场景等问题,本文围绕基线模型以及预训练模型协同建模这一思路来开展研究,重点去探索一种兼顾稳定性以及精细化能力的级联分割方法。全文把视网膜血管等典型线状结构数据当作主要实验对象,结合现有的模型设计、参数高效微调策略以及分割评价体系,对级联分

割框架的构建以及优化去开展系统的研究。

首先，本文对线状结构分割任务的特性以及它的关键技术进行了分析，梳理了医学图像分割、视觉 Transformer、SAM 以及参数高效微调等相关理论基础，同时结合视网膜血管分割任务的特性，明确了区域精度、结构连续性以及边界质量在该研究当中的重要性。在此基础之上，选取对线状结构具备较好建模能力的 LSSeg 去作为基础分割网络，分析它在细长结构提取、局部细节保持以及特征传递方面的优势，从而为后续进行级联架构设计提供稳定的粗分割先验。

其次，围绕预训练分割模型在医学图像场景当中的适配问题，本文研究了 SAM 在微观图像分割任务当中的应用方式，并且选用 LoRA 对它开展参数高效微调，以此降低大模型在迁移过程当中的计算开销以及训练成本。考虑到 SAM 原生框架会依赖外部 prompt 输入，要是医学图像自动分割任务，就更强调端到端以及自动化处理的能力，因此本文重点去探索如何借助 LSSeg 的分割结果去自动构造 mask prompt 以及 box prompt，同时会把它们作为 SAM-LoRA 的输入，以此来实现由粗到细的级联分割流程。

再次，针对原始级联方式当中可能会出现训练不稳定、粗分割信息利用不足以及 SAM 分支难以稳定去提升整体性能等问题，本文进一步研究了级联架构当中的关键优化策略。具体囊括了：设计以 LSSeg 为主、SAM-LoRA 为细化分支的级联结构；研究鉴于粗分割结果来开展的 prompt 构造方法以及它的偏置增强策略，以此来提升对细小血管以及复杂边界区域的召回能力；设计融合机制，让 SAM 分支能够在保留基线分割稳定性的基础上去对局部区域开展增量修正工作；同时结合分层学习率、参数分组优化以及训练策略控制，来提高整个级联模型的可训练性以及鲁棒性。

最后，本文在多个公开数据集上去对所提出方法开展实验验证，并且从区域指标、结构指标以及边界指标等多个维度进行了综合分析。实验部分会把单独的 LSSeg 基线、SAM 适配模型以及级联模型去进行对比，同时结合不同的 prompt 设计、融合方式以及训练配置来开展消融实验，以此验证各个关键模块对整体性能所产生的影响。凭借上述研究，本文希望能构建出一种适宜微观图像线状结构分割的有效方法，为视网膜血管等医学图像目标的自动分析提供更加稳定以及精细的技术支持。总体流程图如图 1.3 所示。




图 1.3 研究内容流程图

1.4 章节安排

全文共分为五章，具体安排如下。

第一章为绪论，主要介绍本文的研究背景与研究意义，分析微观图像线状结构分割任务的现实需求与技术难点，综述国内外在医学图像分割、线状结构分割、视觉基础模型及参数高效微调等方面的研究现状，并在此基础上明确本文的主要研究内容与整体研究思路。

第二章为相关理论基础，主要去介绍本文所涉及的核心理论以及关键技术，囊括了图像分割的基本概念、医学图像分割常用的评价指标、视觉 Transformer 以及 SAM 模型的基本原理、参数高效微调当中的 LoRA 方法，以及 LSSeg 网络当中与线状结构建模相关的关键模块。凭借本章内容，来为后续的方法设计以及实验分析提供一定的理论支撑。

第三章为鉴于 LSSeg 以及 SAM-LoRA 来开展的级联架构设计，它是全文的核心章节。本章会结合当前项目的具体实现，重点去开展对 LSSeg 粗分割模块以及 SAM-LoRA 精细分割模块协同方式的介绍，说明鉴于粗分割结果去构造 mask prompt 以及 box prompt 的方法，分析 prompt 偏置增强、残差融合以及分层训练等关键策略，并且给出整体级联框架的设计思路以及实现流程。

第四章为实验结果与分析，主要去介绍实验环境、数据集划分、训练配置以及评价指标设置，并且在 STARE、RITE、CHASE_DB1、HRF 等公开数据集上，对 LSSeg 基线模型、SAM 适配模型以及本文所提出的级联模型开展对比实验。同时，本章还会结合消融实验，去对 prompt 构造、融合方式、训练策略等关键因素对分割结果所产生的影响进行分析，从区域、结构以及边界等多个维度来评价所提方法的有效性以及它的局限性。

第五章为总结与展望，主要去对全文的研究工作开展总结，概括本研究在微观图像线状结构分割任务当中的主要工作以及实验结论，并且结合当前方法在模型稳定性、结构保持能力以及跨数据集泛化能力等方面的不足，对后续可能会有的改进方向去开展展望工作。

第 2 章 相关理论基础

2.1 图像分割基础理论

2.1.1 分割任务定义

图像分割是计算机视觉当中的基础任务之一，它的目标是去按照像素级或者区域级的语义信息，把图像划分成若干具备一致属性的目标区域以及背景区域。与图像分类仅仅输出整体类别、目标检测只去给出目标位置有所不同，图像分割要求模型对图像当中的每一个像素去给出明确的类别判断，因此它能够更加精细地去刻画目标的形状、边界以及空间分布情况^{[7][8]}。在开展医学图像分析工作当中，图像分割通常会被用于器官轮廓提取、病灶区域定位、血管结构识别以及组织形态测量等任务里，它是开展后续定量分析、辅助诊断以及治疗规划工作的重要基础^[8]。

从数学的角度来看，图像分割能够被理解为建立一个从输入图像到像素标签集合的映射过程。设定输入图像为 $I \in \mathbb{R}^{H \times W \times C}$ ，其中 H 以及 W 分别表示图像的高以及宽， C 表示通道数，那么图像分割模型的目标就是去学习一个映射函数 $Y = f(I)$ ，让它输出分割结果 $I \in \{0, 1, \dots, k-1\}^{H \times W}$ ，其中 k 表示类别数。要是任务属于二分类分割，它的输出通常会去表示目标区域以及背景区域；如果任务是多分类分割，那就会输出每个像素所属的具体类别。在本文所研究的视网膜血管等线状结构分割任务当中，分割通常会属于二分类语义分割，也就是去把血管区域以及背景区域区分开来。

与自然图像当中的一般场景分割相比，医学图像分割会具备更强的专业性以及任务依赖性。一方面，医学图像当中的目标区域往往会具备较强的结构约束，比如器官边界、病灶形态或者血管走向，这要求模型不仅能够去识别区域位置，同时还要保持它的结构合理性；另一方面，医学图像常常会伴随低对比度、噪声、模糊以及样本数量有限等问题，这使得分割任务不仅是去处理像素分类的工作，更是一个融合了结构先验、上下文语义以及任务知识的复杂建模过程^{[10][20]}。因此，去建立适宜具体医学场景的分割模型，是提升分割效果以及临床可用性的关键所在。

2.1.2 分割任务分类

根据任务目标以及输出形式的不同,图像分割通常可以分为语义分割、实例分割以及全景分割这三类。语义分割关注像素所属类别,不去区分同类目标间的个体差异;实例分割则在像素分类基础上进一步去区分同一类别当中的不同实例;全景分割综合了语义分割以及实例分割的特性,既要去识别背景区域语义类别,也要去区分前景目标的不同实例。对医学图像分析而言,由于许多任务更关注目标区域整体形态以及它的组织结构,而不强调同类个体目标间的实例区分,故而语义分割是最常见、应用最广泛的任务类型^{[8][10]}。

从类别数量角度来看,图像分割还能被分为二分类分割以及多分类分割。二分类分割通常被用于开展目标以及背景的区分,比如血管分割、病灶提取以及器官区域检测等;多分类分割则常用于同时识别多个器官或者组织类型,像脑组织分割、腹部器官分割以及病理组织分类等。本文所研究的视网膜血管分割任务,实质上属于典型的二分类语义分割问题,它的输出结果为血管像素以及背景像素的二值掩膜。

此外,从数据维度以及建模对象角度,还能把图像分割划分为二维图像分割、三维体数据分割以及时序图像分割等类型。二维分割主要针对单幅图像去开展像素级识别,是目前显微图像、眼底图像以及病理切片分析当中的主流形式;三维分割则常被应用于 CT、MRI 等医学体数据中,需要同时考虑体素空间关系;时序图像分割则强调在时间维度上的连续性建模。本文运用的数据主要为二维眼底图像,故研究重点集中在二维医学图像当中的线状结构语义分割问题上。

从任务难度以及目标形态来看,线状结构分割又属于语义分割当中的特殊类型。与一般区域型目标相比,线状结构通常具备细长、分支多、局部对比度低以及拓扑关系复杂等特性,因此该类任务不仅要求模型能正确识别目标区域,还要求在分割结果中尽可能保持结构连续性、分支完整性以及边界准确性^{[19][20][27]}。也正因如此,线状结构分割往往需要在网络结构、损失函数以及评价指标上去开展专门设计,而不能简单沿用一般图像分割的处理方式。

设预测分割结果为 P , 真实标注为 G , 二者均为二值集合; 其中, $|A|$ 表示集合 A 当中元素的个数。进一步, 设真阳性、假阳性以及假阴性的像素数分别为 TP 、 FP 以及 FN 。在评价过程当中, 模型首先去输出像素级概率图, 随后针对 DSC 、 $mIoU$ 、 $clDice$ 、 $ASSD$ 以及 $95HD$ 等指标, 运用固定阈值去把概率图二值化, 而 AP 以及 ODS 则是鉴于连续概率输出来开展统计。这样的设计能同时反映出模型在固定判决标准下的分割质量, 以及在不同阈值下的整体排序能力。

Dice 系数 (Dice Similarity Coefficient, DSC) 是医学图像分割中最常用的区域重叠指标之一, 其定义为

$$DSC = \frac{2|P \cap G|}{|P| + |G|} = \frac{2TP}{2TP + FP + FN} \quad (2-1)$$

Dice 系数被用于去衡量预测区域以及真实区域的重合程度，其取值范围为 $[0, 1]$ ，数值越大说明分割结果以及真实标注越接近。针对前景偏小的医学图像任务，DSC 相比普通准确率更能去反映模型对目标区域的识别能力，故而被广泛当作核心评价指标运用。

交并比（Intersection over Union, IoU）用于衡量预测区域与真实区域的交集相对于并集的比例，其定义为

$$IoU = \frac{|P \cap G|}{|P \cup G|} = \frac{TP}{TP + FP + FN} \quad (2-2)$$

本文把平均交并比也就是 mean IoU，即 mIoU，当作区域重叠类指标之一来使用。与 DSC 相比，IoU 对假阳性以及假阴性会更加敏感，因此它能够从另一角度去补充说明模型在开展前景区域提取工作方面的准确程度。对于线状结构分割任务而言，把 DSC 以及 mIoU 进行联合运用，会有助于更全面地去刻画区域层面当中的预测质量。

针对前景像素稀疏以及类别分布不均衡的问题，本文运用平均精度也就是 Average Precision，即 AP，去衡量模型在不同阈值之下的整体检测能力。AP 本质上就是精确率以及召回率曲线下方的面积。其中，精确率以及召回率分别被定义为

$$Precision = \frac{TP}{TP + FP} \quad (2-3)$$

$$Recall = \frac{TP}{TP + FN} \quad (2-4)$$

在此基础上，AP 可表示为精确率-召回率曲线的积分面积，即

$$AP = \int_0^1 Precision(R) dR \quad (2-5)$$

其中 R 去表示召回率。要是 AP 越大，说明模型在不同阈值之下越能去兼顾精确率以及召回率。对视网膜血管等线状结构任务而言，AP 能够较好反映模型对细小血管以及弱响应区域的整体识别能力。然而，仅有区域重叠类指标仍不足以去准确反映线状结构的拓扑保持能力。因此，本文进一步把 clDice 当作结构连续性评价指标来运用^[19]。设 $S(A)$ 表示骨架提取算子，则可分别定义鉴于真实骨架的覆盖率以及鉴于预测骨架的覆盖率为

$$T_G = \frac{|S(G) \cap P|}{|S(G)|} \quad (2-6)$$

$$T_P = \frac{|S(P) \cap G|}{|S(P)|} \quad (2-7)$$

据此，clDice 定义为

$$clDice = \frac{2T_G T_P}{T_G + T_P} \quad (2-8)$$

与传统的 DSC 有所不同, $clDice$ 会更加去强调预测结果对于中心线结构以及拓扑连通关系的保持能力, 故而它特别适宜运用在血管、神经纤维以及细胞轴突等管状或者线状结构分割任务当中。要是 $clDice$ 较高, 那通常就说明模型在分支延续性、结构完整性以及拓扑合理性等方面具备较好的表现。

除了区域以及结构指标之外, 边界定位误差同样也是去评价医学图像分割结果的重要方面。所以, 本文引入了平均对称表面距离也就是 ASSD, 以及 95% Hausdorff 距离即 95HD 这两类边界指标。设定预测边界以及真实边界分别为 ∂P 以及 ∂G , 并把点到集合的最小欧氏距离记作 $d()$, 那么 ASSD 就可以被表示为

$$ASSD = \frac{\sum_{p \in \partial P} d(p, \partial G) + \sum_{g \in \partial G} d(g, \partial P)}{|\partial P| + |\partial G|} \quad (2-9)$$

ASSD 被用于去反映预测边界以及真实边界间的平均偏差, 它的值越小说明边界整体越接近真实的标注。相比之下, Hausdorff 距离会更加去关注边界间的最大偏差。为了减弱极端离群点影响, 本文运用 95% Hausdorff 距离, 它的定义为

$$95HD = \max \{P_{95}(d(p, \partial G)), P_{95}(d(g, \partial P))\} \quad (2-10)$$

P_{95} 去表示距离分布当中的 95% 分位数。要是 95HD 越小, 那就说明模型在大多数边界位置上的最大偏差越小。对于需要去开展血管宽度估计、边缘测量以及形态分析等任务而言, ASSD 以及 95HD 具备着重要的参考价值。此外, 为了评价模型在统一阈值标准之下的整体检测性能, 本文还运用了最优数据集尺度指标也就是 Optimal Dataset Scale, 即 ODS。设定阈值为 τ 时, 全数据集上的精确率以及召回率分别为 $Precision(\tau)$ 以及 $Recall(\tau)$, 那么对应的 F1 值就为

$$F_1(\tau) = \frac{2 \cdot Precision(\tau) \cdot Recall(\tau)}{Precision(\tau) + Recall(\tau)} \quad (2-11)$$

据此, ODS 定义为

$$ODS = \max_{\tau} F_1(\tau) \quad (2-12)$$

该指标借助在全数据集范围内搜索统一阈值下的最佳 F1 值, 以此反映模型在统一决策标准下的总体检测效果。针对需要去比较不同模型整体判决稳定性的实验场景, ODS 具备较好的参考意义。

综上所述, 本文运用 DSC、mIoU 以及 AP 去评价模型的区域级分割能力, 选用 $clDice$ 衡量线状结构的拓扑连续性以及分支完整性, 运用 ASSD 以及 95HD 去刻画边界定位误差, 同时把 ODS 当作评价模型在统一阈值下整体检测性能的指标来使用。要是模型在上述多个维度上同时取得较优结果, 才能够说明它真正具备较强的微观图像线状结构分割能力。

2.1.3 医学图像分割常用评价指标

评价指标是去衡量图像分割模型性能的重要依据。在医学图像分割任务当中，不同模型可能会在区域重叠、细小结构召回、拓扑连续性以及边界定位等方面表现出不同的优势，故而仅仅依靠单一指标往往难以全面去反映出模型的真实能力^{[10][20]}。对于本文所研究的视网膜血管等线状结构分割任务而言，这一问题表现得尤为突出。血管目标通常具备细长、分支丰富、前景占比较小等特性，模型即使在整体区域重叠上取得了较高分数，也可能依然会把细小分支遗漏，或者存在局部断裂以及边界偏移等问题。因此，本文从区域重叠、概率排序、结构连通性以及边界误差这四个维度去对模型开展综合评价。

2.2 视觉 Transformer 与 SAM 模型

2.2.1 Vision Transformer 基本原理

Transformer 最初被广泛运用于自然语言处理任务当中，它的核心优势在于能够借助自注意力机制去开展序列内部长距离依赖关系的建模工作。随着视觉任务的不断发展，研究者开始尝试把 Transformer 引入图像处理领域，并且形成了视觉 Transformer 即 Vision Transformer 也就是 ViT 这一重要研究方向^[25]。与卷积神经网络主要依靠局部感受野以及层层堆叠去逐步扩大感受范围有所不同，视觉 Transformer 能够在开展特征建模的过程当中，直接去建立全局范围内的像素或者图像块之间的关系，故而在进行复杂场景理解、全局上下文建模以及跨区域信息交互等方面具备明显的优势^[12]。

Vision Transformer 的基本思想就是去把二维图像转化为类似于自然语言当中词序列的输入形式。具体而言，输入图像首先会被划分成若干固定大小的图像块也就是 patch，每个 patch 在经过拉平以及线性映射之后，会形成对应的嵌入向量，然后再与位置编码相加以此来保留空间位置信息，最终去构成可供 Transformer 编码器处理的序列输入。凭借多层多头自注意力机制以及前馈网络的堆叠，模型能够去学习不同图像块之间的相关性，并且在全局范围内去提取具备判别性的特征表示。

与卷积网络相比，视觉 Transformer 会更擅长去捕获远距离依赖以及整体结构信息，这就使得它在大尺度目标建模以及复杂语义理解任务当中表现得更为突出。然而，Transformer 对训练数据规模以及计算资源通常具备更高的要求，并且在去处理局部纹理细节以及小样本任务时，往往需要把卷积结构、分层设计或者预训练策略结合起来运用，才能够去充分发挥它的优势。因此，在医学图像分割领域当中，

视觉 Transformer 更多地会被用来增强全局上下文的建模能力，而不是去完全替代卷积网络。

对于本文所研究的微观图像线状结构分割任务而言，视觉 Transformer 的价值主要体现在两个方面。一方面，线状结构通常具备较长的空间延展性以及复杂的分支关系，单纯依靠局部卷积特征有时难以去充分建模不同区域之间的全局关联，而 Transformer 会有助于去增强模型对于整体结构走向以及远距离依赖的理解^[12]；另一方面，随着大规模预训练模型的不断发展，鉴于 Transformer 开展的视觉基础模型已经能够借助预训练去获得较强的通用表示能力，这就为后续在医学图像任务当中引入迁移学习以及参数高效微调提供了相应基础。SAM 正是在这一技术背景之下被提出的代表性视觉基础分割模型。

2.2.2 SAM 模型架构

Segment Anything Model 也就是 SAM，是 Meta 所提出的通用分割基础模型。它的目标是凭借大规模数据预训练以及提示驱动机制，让任意目标区域的灵活分割得以实现^[15]。和传统分割模型直接从图像去预测固定类别掩膜有所不同，SAM 会更加去强调“可提示分割”这一思想，也就是借助点、框、掩膜等外部提示信息，去引导模型对用户所关注的目标区域开展分割工作。这种设计让 SAM 在自然图像领域当中表现出了较强的通用性以及交互能力，同时推动了“基础模型 + prompt”范式在视觉分割任务当中的广泛关注。图 2.2 展示出了 SAM 的总体结构。该模型是由图像编码器、提示编码器以及掩膜解码器这三部分来组成的，体现出了典型的提示驱动分割范式。




图 2.2 SAM 模型架构图

从整体结构上看，SAM 主要是由图像编码器、提示编码器以及掩膜解码器这三个部分来组成的^[15]。图像编码器通常基于视觉 Transformer 来开展工作，用于把

输入图像去映射成高维的特征表示，并且提取它当中的全局语义以及空间结构信息。提示编码器负责去对外部输入的提示开展编码工作，这囊括了点提示、框提示以及已有掩膜提示等，以此让不同类型的先验信息能够被统一进行表示，同时与图像特征去开展对齐工作。掩膜解码器则在图像特征以及提示特征的共同作用之下，去输出目标区域所对应的分割掩膜以及它的质量评估信息。这三者开展协同工作，从而让模型能够根据不同提示去实现灵活的目标分割。

从计算过程看，设输入图像为 I ，输入提示为 p ，则 SAM 的图像编码和提示编码过程可分别表示为

$$E_{img} = f_{img}(I) \quad (2-13)$$

$$E_{prompt} = f_{prompt}(P) \quad (2-14)$$

其中 $f_{img}()$ 去表示图像编码器， $f_{prompt}()$ 去表示提示编码器， E_{img} 以及 E_{prompt} 分别去表示图像嵌入以及提示嵌入。在此基础之上，掩膜解码器就可以表示为

$$M_{low} = f_{dec}(E_{img}, E_{prompt}) \quad (2-15)$$

其中 M_{low} 去表示低分辨率掩膜预测结果。进一步开展上采样，便可得到与原图尺寸一致的最终分割结果

$$\hat{M} = Upsample(M_{low}) \quad (2-16)$$

上述过程说明，SAM 并不是直接去对固定类别开展分割工作，而是在图像特征以及外部提示共同约束之下生成目标掩膜。这种“图像编码 + 提示编码 + 掩膜解码”的结构设计，是它具备较强提示驱动分割能力的关键缘由。

SAM 的优势主要体现在两个方面。首先，依托大规模预训练数据，SAM 能够去学习到较强的通用视觉先验，在自然图像当中具备良好的泛化性；其次，提示编码机制让它不再局限于固定类别的分割，而是能够根据输入提示去对不同目标开展快速响应。这种特性对于医学图像任务具备一定吸引力，主要是因为医学图像当中往往存在结构复杂、尺度变化大以及标注代价高等问题，要是能把通用分割先验以及医学场景当中的任务知识结合起来，在理论上有望去提高模型在复杂目标分割当中的适应能力。

然而，SAM 原生模型主要面向自然图像来构建，它的分割性能在医学图像场景当中并不一定能够直接去迁移。一方面，医学图像的纹理特征、目标尺度、灰度分布以及标注方式与自然图像存在着显著差异；另一方面，SAM 对 prompt 依赖较强，而在真实的医学自动分割任务里，人工逐一去提供点、框或者掩膜提示的方式并不适宜大规模的自动化应用。因此，如何借助已有的医学分割模型去自动生成有效的 prompt，同时凭借轻量化微调让 SAM 更好地去适宜医学场景，就成为了

当前研究的重要方向。

在本文当中，SAM 的作用并不是去直接替代专用分割模型，而是把它当作精细化修正模块参与到级联分割的过程当中。具体而言，本文借助 LSSeg 先对输入图像开展粗分割，再把它的输出结果转化为 mask prompt 以及 box prompt，输入到经过 LoRA 适配之后的 SAM 模块里去进行进一步的细化工作。这样的设计既运用了 SAM 在全局建模以及提示驱动分割方面的优势，同时也避免了它完全依赖人工 prompt 以及直接迁移医学场景时稳定性不足的问题。因此，去理解 SAM 的基本架构以及它的 prompt 驱动机制，是后续开展 LSSeg 以及 SAM-LoRA 级联模型研究的基础。

2.3 参数高效微调技术

2.3.1 全量微调与参数高效微调对比

随着预训练大模型在自然语言处理以及计算机视觉领域的快速发展，借助已有的大模型来开展迁移学习已经成为了提升下游任务性能的重要途径。传统的迁移学习方式通常会选用全量微调，也就是在目标任务上去对预训练模型的全部参数开展更新工作。这种方式能够最大程度地让模型的表示能力得以实现，但也伴随着较高的计算成本、显存开销以及训练时间，尤其是当模型参数规模巨大并且下游任务数据量有限的时候，全量微调不仅代价昂贵，还极易引发过拟合以及训练不稳定等问题^{[15][26]}。

在医学图像分析场景当中，这一问题表现得尤为突出。一方面，医学任务常会运用高分辨率图像或者三维体数据，对显存资源以及训练效率要求较高；另一方面，医疗数据获取以及标注的成本比较大，训练样本数量通常要远少于自然图像任务。在这种情况下，要是大规模预训练模型开展全量微调，不仅训练成本高，同时模型在小样本数据上的泛化能力也不一定理想。因此，如何在尽量保留预训练模型原有通用能力的基础之上，凭借较少的参数更新来实现对目标任务的快速适配，已经成为了当前研究当中的重要问题。

参数高效微调也就是 Parameter-Efficient Fine-Tuning，即 PEFT，正是在这一背景之下被提出的。它的核心思想是在把大部分预训练参数冻结的前提之下，仅仅引入少量额外的可训练参数，或者只对部分关键模块开展更新工作，从而以较低的资源消耗去完成对下游任务的适配。与全量微调相比，参数高效微调通常具备以下特性：第一，可以极大程度地降低训练参数量以及显存占用，减轻硬件方面的负担；第二，能够去减少对原始预训练参数的破坏，让模型保留较强的通用先验；第三，

更适宜于小样本任务以及多任务迁移场景，便于在不同任务之间开展快速切换以及复用模型^[17]。正因如此，参数高效微调已经成为了当前大模型医学适配研究当中的重要技术路线。

2.3.2 LoRA 原理

在众多的参数高效微调方法当中，低秩自适应也就是 Low-Rank Adaptation，即 LoRA，凭借它实现简洁、训练稳定以及适用范围广等特性而得到了广泛关注^[26]。它的基本思想在于：在不直接去更新原始权重矩阵的情况之下，把目标层的参数更新去表示成一个低秩矩阵分解方面的形式，仅仅去训练分解之后的低秩矩阵参数，同时会保留原始的预训练权重不发生改变。通过这样一来，模型在适配新任务的时候只需要去学习少量的新增参数，就能够在较低代价之下获得较好的迁移效果。图 2.3 展示出了 LoRA 的基本适配结构。它当中的核心思想在于，在冻结原始权重的基础之上，去引入低秩矩阵分支来开展对任务相关增量信息的学习工作。




图 2.3 LoRA 低秩适配图

具体来讲，假设某一线性变换层的原始权重矩阵是 $W \in R^{(d \times k)}$ ，在传统的全量微调过程当中，是需要直接去开展该矩阵增量的学习工作的。而在 LoRA 当中，参数更新量 ΔW 会被近似地去表示成两个低秩矩阵的乘积，也就是 $\Delta W = BA$ ，这当中 $A \in R^{(r \times k)}$ ， $B \in R^{(d \times r)}$ ， r 是远小于 d 以及 k 的秩值。如此一来，模型的实际权重就变为了 $W' = W + \Delta W = W + BA$ 。由于只需要去训练低秩矩阵 A 以及 B ，新增的参数量得以大幅度减少，从而显著程度地降低了训练成本。

LoRA 的有效性建立在这样一种假设之上：针对许多下游任务而言，预训练权重在开展迁移的过程当中，并不需要去进行大规模的自由更新，它的适配变化往往可以凭借一个低秩空间里的增量来开展近似表示^[26]。鉴于这一思想，LoRA 既保留了原始模型当中凭借大规模预训练所获得的通用知识，又通过低秩参数学习补充了面向特定任务的调整能力。此外，LoRA 通常可以直接被插入到注意力层或者前馈

层等线性映射模块里，不需要去对原始网络结构开展大规模的改动，故而具备较好的可移植性以及工程实现的便利性。

从训练过程来看，LoRA 通常会把原始主干参数冻结，仅仅去对新增的低秩矩阵开展梯度更新的工作，这让它能够在较低的资源消耗之下完成模型适配。推理阶段则可以选择去保留 LoRA 分支，也可以把它以及原始权重开展合并工作，从而不会显著程度地增加推理复杂度。针对需要在有限计算资源之下去处理高分辨率医学图像的任务而言，LoRA 提供了一种兼顾效率以及性能的可行方案。

2.3.3 LoRA 在视觉模型中的应用

最初，LoRA 主要被运用于自然语言处理当中的大语言模型微调工作，随后逐步扩展到了视觉 Transformer 以及多模态模型等领域当中^[26]。鉴于视觉基础模型通常具备较大的参数规模以及较强的预训练能力，故而在图像分类、目标检测以及图像分割等任务当中，运用 LoRA 来开展参数高效适配工作已经成为了一种重要思路。尤其是在基于 Transformer 来开展的视觉模型当中，注意力模块以及线性投影层天生适宜去插入低秩适配分支，这让 LoRA 能够较为方便地被运用在图像编码器以及跨模态交互模块当中^{[17][18]}。

在医学图像任务当中，LoRA 的应用价值表现得更加明显。首先，医学数据的规模通常较为有限，而预训练视觉模型又多是来源于自然图像的大型数据集，直接开展全量微调不仅成本偏高，还可能会破坏掉原有的通用知识表示；其次，医学图像往往具备较强的任务差异性，不同器官、不同模态以及不同成像条件之下的目标特征差别比较大，运用 LoRA 可以在把大部分参数冻结的基础之上，为特定任务去学习额外的适配能力，从而提高模型迁移的灵活性以及稳定性。

对于基于 SAM 来开展的医学图像分割研究而言，LoRA 已经成为了常见的适配方式之一。鉴于 SAM 的图像编码器规模偏大，如果开展全量微调工作就会带来较高的显存以及时间开销，故而研究人员通常会选择在它的注意力相关层当中去插入 LoRA 分支，仅仅去训练新增参数，并且结合提示编码器或者掩膜解码器来实现面向医学任务的轻量化适配^{[17][18]}。这样既能够运用 SAM 在大规模数据预训练当中所获得的通用视觉先验，又可以让模型在特定医学图像分割任务当中逐步去学习更契合目标场景的特征表示。

在本文所研究的级联分割框架当中，LoRA 的作用正是为了实现 SAM 从通用自然图像分割模型向微观图像线状结构分割模型的高效迁移。具体来讲，本文在保留 SAM 整体架构优势的基础之上，对它的关键编码模块开展 LoRA 适配工作，并且结合 LSSeg 所生成的 prompt 信息，引导模型去完成对细小血管以及复杂边界区域的进一步细化工作。这种做法既降低了去直接微调大模型的资源开销，也为

级联分割架构的训练以及部署工作提供了更加现实的工程路径。

2.4 LSSeg 线状结构分割网络

LSSeg 是一种面向线状结构分割任务所设计的专用网络，它的核心目标是在保持网络整体轻量性的同时，去提高模型对细长目标、连续分支以及局部边界细节的表达能力。与面向一般区域分割的通用网络相比，LSSeg 会更加去强调线状结构在空间分布上的延展性、方向性以及连通性，因此在网络结构设计上会去引入更加适宜细粒度结构建模的模块组合^[19]。在本文的级联框架当中，LSSeg 会被当作前端粗分割模型来使用，它承担着去生成稳定结构先验以及初始分割结果的关键作用，是开展后续 SAM-LoRA 精细分割工作的基础。

图 2.4 展示出了 LSSeg 的整体结构。该网络会凭借编码端的多级特征抽取、解码端的逐级重建以及门控跳跃连接，从而让对线状结构的稳定建模以及细节恢复得以实现。




图 2.4 LSSeg 网络结构图

从整体结构上看，LSSeg 选用了由编码路径以及重建路径来构成的层级式框架，同时凭借多级特征提取工作以及逐级恢复的方式，去完成线状结构分割任务。它当中的编码部分主要由多个特征衰减模块也就是 FDM 构成，被运用来逐层提取输入图像当中的结构特征，并且开展空间分辨率的压缩工作；而解码部分则是依靠重建模块即 RM，来逐步开展空间分辨率的恢复工作，并且去输出最终的分割结果。同时，在编码特征以及解码特征之间，LSSeg 引入了门控跳跃连接也就是 GSC，来增强浅层细节信息以及深层语义信息之间的有效融合，从而能够去减少传统跳跃连接当中，无关特征直接传递所带来的干扰。

若将输入图像记为 X ，则 LSSeg 的编码过程可概括为

$$X_i = FDM_i(X_{i-1}), \quad i = 1, 2, \dots, K \quad (2-17)$$

其中 X_i 表示第 i 个编码阶段输出特征， K 表示网络层级数。该过程对应于通过 FDM 逐步提取线状结构特征并压缩空间分辨率。

在解码过程中，若记第 i 层解码特征为 Y_i ，则重建过程可写为

$$Y_i = RM_i(X_i), \quad i = K \quad (2-18)$$

$$Y_i = RM_i(GSC(X_i, Y_{i+1})), \quad i < K \quad (2-19)$$

$RM_i()$ 去表示重建模块， $GSC()$ 也就是门控跳跃连接模块。针对 GSC 而言，它当中的核心思想是凭借门控权重，在编码特征以及解码特征之间去开展自适应融合。要是把门控函数记作为 $\sigma()$ ，把激活函数记作为 $\phi()$ ，那么它的形式就可以写作为

$$g = \sigma(\text{Conv}([X_i, Y_{i+1}])) \quad (2-20)$$

$$\tilde{X}_i = \phi(X_i \odot g + Y_{i+1} \odot (1 - g)) \quad (2-21)$$

$[X_i, Y_{i+1}]$ 代表通道维度的拼接工作，而 $\odot$ 则去表示逐元素的乘法运算。这一设计可以根据不同层级特征的重要性来自动开展融合比例的调节工作，从而在实现浅层细节保留的同时，去抑制无关噪声的传播。

在具体的模块设计方面，LSSeg 的一个重要特性便是引入了 RFCACnv 模块。该模块在网络前端特征提取当中去发挥关键作用，它的思想是把感受野扩展以及坐标注意力机制结合起来，在开展局部感受范围增强工作的同时，去实现对空间位置信息的保留^[28]。针对线状结构分割任务而言，细小的血管以及纤维目标通常尺度较小、方向多变，同时对局部纹理以及空间位置表现得十分敏感，要是单纯依靠普通的卷积，就极易造成结构响应不足的情况。RFCACnv 借助去生成更加丰富的局部上下文特征，并且把横向以及纵向的注意力建模结合起来，会有助于提升网络对于细长目标方向性以及空间连续性的感知能力。

若将 RFCACnv 生成的中间特征记为 F ，横向和纵向注意力权重分别记为 A_h 与 A_w ，则其核心计算思想可概括为

$$F' = F \odot A_h \odot A_w \quad (2-22)$$

$$Y = \text{Conv}(F') \quad (2-23)$$

也就是先凭借坐标注意力去对特征在水平以及垂直方向上开展重标定的工作，再依靠卷积映射去获得输出特征。这一机制会有助于去增强模型对于线状目标走向方面的信息以及空间连续关系的建模能力。

FDM 是 LSSeg 编码阶段当中的重要组成部分，它的主要作用是在下采样过程当中去完成多层次特征的抽取以及压缩工作。把密集连接式的特征传递方式结合起

来，FDM 能够在较少参数量之下去实现更充分的局部信息利用，从而提高浅层纹理特征以及深层语义特征之间的关联。针对线状结构而言，这种多层特征累积方式会有助于去缓解细小目标在深层网络当中逐渐消失的问题，从而去保留更多与边缘、走向以及分支相关的细节信息。

在解码阶段，LSSeg 借助 RM 对深层特征开展逐步的上采样以及空间重建工作。RM 凭借上采样去恢复目标区域的空间分布，让网络可以在较高分辨率之下重建线状结构的整体形态。由于线状目标往往具备细而长、边界窄、分支多等特性，上采样过程要是开展的处理工作不太妥当，就极易导致分割结果变粗、断裂或者是边界模糊。因此，RM 在 LSSeg 当中不仅承担尺度恢复的功能，同时也承担着对结构细节去开展重建的任务。

GSC 则是 LSSeg 区别于普通编码器-解码器结构的另一关键模块。这一模块依靠学习门控权重，对编码端特征以及解码端特征开展自适应融合工作，而不是简单地去进行直接拼接或者相加。这样做的优势在于，网络可以根据不同层级特征的重要性，去自主决定浅层细节以及深层语义的融合比例，从而在去保留细节信息的时候，同时也抑制了无关噪声的传播。针对背景复杂、低对比度的微观图像而言，这种门控式特征融合会更有利于去提高分割结果的稳定性以及结构合理性^{[20][27]}。

把当前项目的实现方式结合起来，LSSeg 在本文当中不只是被当作独立基线模型参与对比实验，还被进一步运用在级联框架当中去生成粗分割结果。具体而言，LSSeg 首先对输入图像输出初始分割 logits，随后这些结果会被转化成 mask prompt 以及 box prompt，当作后续 SAM-LoRA 细化分支的先验输入。也就是说，LSSeg 在本文当中既是在去承担基础分割网络的角色，同时也在去承担 prompt 生成器的角色。因此，选用对线状结构具备较强表达能力的 LSSeg 当作级联前端，不单能够保证整体框架具备稳定的保底性能，同时也为后续凭借大模型开展局部的精细修正工作提供了可靠的结构先验。

第 3 章 LSSeg 与 SAM-LoRA 级联架构设计

3.1 级联架构设计思想

3.1.1 “粗到细” 分割策略

针对微观图像当中的线状结构分割任务，单一模型往往会难以同时去兼顾整体结构的稳定性以及局部边界的精细性。一方面，专用的分割网络通常能够较为稳定地去提取血管、神经纤维等这些细长目标的主体区域，但在复杂背景、弱对比边界以及细小分支处依然可能会存在遗漏或者是边界粗糙等问题；另一方面，基础模型虽然具备较强的全局建模能力以及提示驱动分割能力，但要是缺少了任务先验以及有效的 `prompt` 约束，在医学场景当中往往难以直接获得稳定的结果。鉴于这一矛盾，本文运用了“从粗到细”的级联分割策略，也就是先借助专用模型来生成结构稳定的粗分割结果，再运用基础模型去对局部难分区域开展进一步的细化工作，从而在整体层面上兼顾了稳定性以及精确性。


“从粗到细”策略的核心思想在于对任务开展分解工作。针对线状结构分割而言，粗分割阶段的主要目标是去尽可能完整地识别出目标主体，从而保证主干血管以及主要的分支能够被稳定地保留；细化阶段的主要目标则是凭借更强的表示能力以及更丰富的上下文信息，去对边界模糊区域、细小分支以及局部断裂区域开展修正以及补充工作。这种分工方式和人工分析的过程较为一致：先去识别整体结构，再进一步去判断细节区域是否属于目标，从而减少了单阶段模型在复杂任务当中同时去兼顾所有目标所带来的困难。

从当前项目的实现方式来看，本文的级联流程可以概括为以下几个步骤。首先，把输入图像送入 LSSeg 网络当中，获得初始分割 `logits`，把它当作对线状结构的粗分割结果来运用。其次，对该粗分割结果开展进一步处理，把它下采样为适宜 SAM `prompt encoder` 输入的 `mask prompt`，同时把预测区域结合起来去生成 `box prompt`，以此增强提示信息对目标区域的约束能力。然后，把原始图像以及 `prompt` 一同送入到经过 LoRA 适配之后的 SAM 模块里，由它来对局部区域开展精细化分割。最后，把 SAM 输出结果以及 LSSeg 粗分割结果进行融合，从而得到最终的分割结果。整个过程体现出了由专用模型提供结构先验、由基础模型开展细化修正的设计思路，总体的架构图如图 3.1 所示。

选用“从粗到细”策略的另一个重要缘由在于，它更契合线状结构分割任务对

于结构连续性以及局部细节同时敏感的特性。要是直接依靠基础模型从原始图像去生成最终掩膜，那么模型就需要在缺少明确任务先验的情况之下，同时去完成目标定位、结构建模以及边界恢复工作，训练难度偏高，结果也极易受到 **prompt** 质量的影响。而在本文的设计当中，**LSSeg** 已经先对目标区域提供了较为稳定的初始定位以及结构约束，**SAM-LoRA** 的任务便不再是“从头开展分割”，而是“在已有先验之上修正细节”，这使得后续的精细化模块更容易去聚焦于真正困难的局部区域，从而提高了整体框架的可训练性以及稳定性。

此外，从粗到细的级联策略还具备较好的扩展性。由于前端粗分割网络以及后端精细化模块在功能上具备一定的解耦性，后续可以围绕 **prompt** 构造、融合方式、训练机制以及参数配置等方面来开展针对性的优化工作。比如，可以通过调节 **prompt bias** 来提高疑似目标区域的召回率，凭借 **box** 扩张来增强对微细目标的包络能力，也可以借助残差融合来保留基线模型的下限性能。这些设计都建立在“从粗到细”这一总体架构思想之上，是本文后续开展模型改进的重要基础。



3.1.2 为何选择 LSSeg 与 SAM-LoRA 级联

在确定了级联框架之后，去如何选用合适的粗分割模型以及细化模型便成为了关键的问题。本文最终运用 **LSSeg** 来作为粗分割模块，选用经过 **LoRA** 适配之后的 **SAM** 来当作精细分割模块，它的缘由主要鉴于任务适配性、模型能力互补性以及工程层面的可实现性这三个方面。

首先，从任务适配性来看，**LSSeg** 是面向线状结构分割所设计的专用网络，对细长目标、连续分支以及局部细节具备较好的建模能力^[19]。与一般的语义分割网络相比，**LSSeg** 在结构设计上引入了 **RFCACnv**、**FDM**、**RM** 以及 **GSC** 等适宜线

状目标提取的模块，能够在较轻量的条件之下稳定地提取目标主体结构。这种能力对视网膜血管等任务而言尤为重要，因为粗分割阶段最关键的并不是马上得到极其精细的边界，而是去尽可能完整、稳定地保留主要结构，从而为后续的细化模块去提供可靠先验。所以，选用 LSSeg 当作前端模型，能够保证整个级联框架具备较好的保底性能。

其次，从模型能力互补性来看，SAM 作为大规模预训练的视觉基础分割模型，具备较强的全局建模能力以及提示驱动分割能力^[15]。它的优势并不在于去直接替代专用模型完成医学分割，而是在于要是输入具备了较明确的目标提示，就能把全局语义以及局部特征结合起来，去对目标边界开展更灵活的修正以及细化工作^[16]。这与 LSSeg 的能力形成了较好的互补：LSSeg 擅长在医学场景当中稳定地提取线状结构主体，而 SAM 擅长在给定 prompt 的条件下对复杂边界以及模糊区域去开展进一步的判别工作。把这两者组合起来，就能够在一定程度上兼顾“结构稳定性”以及“细节精细化”这两个通常较难去同时满足的目标。

再次，从工程可实现性以及训练成本来看，直接去对完整的 SAM 开展全量微调工作代价较高，不仅需要较大的显存以及较长的训练时间，也极易在医学小样本数据上出现适配不稳定的情况^{[16][26]}。因此，本文运用 LoRA 对 SAM 开展参数高效微调工作，仅仅对关键模块引入少量的可训练参数，在保留预训练先验的同时去降低迁移成本。这种做法更加契合本文的实验环境以及数据规模条件，同时也便于在多个公开数据集上开展对比实验以及参数调节工作。换言之，选用 SAM-LoRA 而不是全量微调的 SAM，不只是方法层面的考虑，也是面向实际训练资源约束的合理选择。

从当前项目的实现来看，LSSeg 以及 SAM-LoRA 的组合还具备另一个重要的优势，那就是二者之间能够凭借 prompt 去建立起自然的信息传递路径。LSSeg 输出的是像素级的粗分割 logits，这些结果在经过下采样以及偏置增强之后，可以直接被构造成 SAM 所需要的 mask prompt；同时，鉴于粗分割区域还可以进一步去生成 box prompt，从而对目标范围开展更明确的约束工作。也就是说，LSSeg 的输出不只是一个中间分割结果，更是去驱动后续 SAM-LoRA 开展精细化分割工作的核心提示信息。这种由前端专用模型去自动生成后端基础模型 prompt 的方式，让整个系统具备了较强的自动化以及端到端特性，同时也避免了传统 SAM 应用当中对于人工交互提示的依赖。


综上所述，选用 LSSeg + SAM-LoRA 的核心缘由在于：LSSeg 能够提供适宜线状结构任务的稳定粗分割先验，SAM-LoRA 能够运用预训练视觉模型的表示能力去对局部困难区域开展进一步修正，而 LoRA 则为基础模型的医学适配提供了低成本、可训练的实现路径。把这三者结合之后，既能够顺应当前医学图像分割当

中“专用模型 + 基础模型适配”的研究趋势，同时也能够更好地满足本文在微观图像线状结构分割任务当中，对于稳定性、精细性和可实现性的综合要求。

3.2 LSSeg 粗分割模块设计

在本文所提出的级联分割框架当中，LSSeg 粗分割模块去承担着两个核心方面的任务：一是对输入图像当中的线状结构开展初始识别工作，并输出具备较好结构稳定性的粗分割结果；二是为后续的 SAM-LoRA 精分割模块去生成可靠的提示先验。与传统的级联结构当中前端模块仅仅当作简单预处理器有所不同，本文当中的 LSSeg 不仅负责去完成基础分割，还直接去决定了后续 prompt 的质量以及分布特性，因此它的设计以及输出方式对整个框架的性能表现都具备着重要的影响。

从数据流图 3.2 来看，输入到级联模型当中的图像首先会被送入到 LSSeg 粗分割模块里面。在当前项目的实现当中，原始输入图像是以 uint8 形式来表示的，像素取值范围处于[0, 255]之间。在进入 LSSeg 之前，图像首先会被归一化到[0, 1]区间，从而去满足卷积网络在开展训练以及推理时的数值稳定性要求。在经过预处理之后，图像会被送入到 LSSeg 主干网络当中，去输出与输入分辨率保持一致的单通道 logits。这里所输出的是未经 sigmoid 激活的原始分割响应，而不是最终的二值掩膜，这一设计可以为后续 prompt 的构造以及分支融合工作，去实现更丰富的连续置信信息的保留。



选用 LSSeg 当作粗分割模块，主要由于它对线状结构具备较强的适配能力。与一般的语义分割网络相比，LSSeg 在结构设计上会更加去重视细粒度结构的表达以及层级特征的融合，从而能够在较轻量的前置条件之下稳定地提取目标主体^[19]。针对视网膜血管等任务而言，粗分割阶段最为重要的并不是过早地去追求边界层面的精细结果，而是去尽可能完整地保留主干结构以及主要分支。LSSeg 所提供的初始分割结果在整体结构、走向连续性以及主要区域覆盖方面具备较好的表现，故而适宜当作后续细化模块的先验来源。

在当前的框架当中，LSSeg 的输出不单单是用于获得粗分割结果，还会直接参与到 prompt 的构造工作当中。具体而言，LSSeg 输出的 logits 会先经过偏置增强处理，也就是在原始响应之上加入 prompt_bias，以此来适当提升潜在目标区域的召回率。偏置增强后的 logits 会再被下采样为固定尺寸的 mask prompt，并输入到 SAM 的提示编码器也就是 prompt encoder 里面。与直接对 logits 开展硬阈值二值化处理相比，这种鉴于连续响应来构造 prompt 的方式能够保留更多边界附近以及弱响应区域的信息，从而让后续 SAM 分支拥有更充分的判别空间。针对细小血管以及低对比区域而言，这种高召回优先的粗分割策略会有助于降低重要结构在级联过程当中被提前丢弃掉的风险。

除了 mask prompt 之外，LSSeg 粗分割结果还能够进一步被运用于生成 box prompt。在实现方面，本文会根据粗分割区域的空间分布去计算目标的最小包围框，并且把 box_bias 以及 box_expand_ratio 结合起来，去对提示框开展适当的扩张工作，从而提高对细小分支以及边缘区域的覆盖能力。训练阶段要是提供了真实标注，就可以运用真实掩膜去生成更加稳定的 box prompt；推理阶段则由 LSSeg 的预测结果来自动生成 box prompt，从而让整个框架的自动化特性得以保留。这说明，LSSeg 在级联结构当中并不是一个孤立的前端分割器，而是贯穿了后续 prompt 构造过程的关键先验生成模块。

此外，LSSeg 粗分割模块在训练策略方面也具备较好的灵活性。当前项目里凭借 freeze_lsseg 参数来控制它是否参与到联合训练当中：当开展冻结的时候，LSSeg 被当作固定的先验生成器，去为 SAM-LoRA 提供稳定的粗分割输入；当不冻结的时候，LSSeg 会与后续的精细分支共同参与端到端的训练，并且凭借分层学习率来开展优化工作，以此兼顾基线稳定性以及协同适配能力。这种设计让 LSSeg 既能够在实验当中当作独立基线模型来提供对照，也能够级联框架当中根据训练目标，去承担固定特征提取器或者是可学习前端模块的双重角色。

综上所述，LSSeg 粗分割模块在本文方法当中并不只是去承担“先分一次”的简单功能，而是集初始结构识别、先验提供以及 prompt 生成工作于一体。它的输出质量会直接影响到后续精细分支的输入提示以及融合结果，因此，保证 LSSeg 在

粗分割阶段具备较高的结构稳定性以及召回能力，是整个 LSSeg-SAM-LoRA 级联框架能够去取得有效分割性能的关键前提。

3.3 SAM-LoRA 精细分割模块设计

在本文所提出的级联架构当中，SAM-LoRA 精细分割模块所承担的主要任务是在粗分割先验的基础之上，去对线状结构的局部边界、细小分支以及模糊区域开展进一步的修正工作。与把 SAM 当作独立分割模型直接运用于医学图像有所不同，本文当中的 SAM-LoRA 被设计为面向特定任务的细化分支，它当中的输入不仅囊括了原始图像，同时也包含由 LSSeg 自动生成的提示也就是 prompt 信息。所以，本模块的设计重点并不在于“从零开始去完成目标分割”，而是在于“鉴于已有结构先验去完成局部精细化的补偿工作”，这也是它能够更好地去契合医学图像场景的重要缘由。

从输入处理流程来看，进入到 SAM-LoRA 当中的原始图像首先需要去经历标准化以及尺寸对齐的操作。鉴于 SAM 原生模型运用了自身所定义的输入均值以及方差，并且要求固定分辨率的图像输入，因此在目前的实现当中，输入图像会先从 uint8 格式转化为浮点数，再依靠 SAM 的标准均值以及标准差来开展归一化处理；如果图像尺寸以及目标输入尺寸不一致，那就借助双线性插值把它调整到统一的分辨率。依靠这一过程，可以在尽可能保留原始图像结构信息的前提之下，使输入满足预训练 SAM 模型的特征分布要求，从而为后续编码以及 prompt 融合工作提供基础。

在模型结构方面，SAM-LoRA 模块依然保留了 SAM 的基本三部分架构，也就是图像编码器、提示编码器以及掩膜解码器。在这里面，图像编码器负责去从输入图像当中提取全局语义特征；提示编码器把来自粗分割模块的 mask prompt 以及 box prompt 开展编码工作，使其变作可供解码器去运用的提示特征；掩膜解码器则在图像特征以及提示特征的共同作用之下来生成低分辨率分割结果，并且在后续步骤当中开展上采样从而回到原图尺寸。本文在实现过程当中对掩膜解码器的批处理推理过程开展了适配工作，让它可以与目前的训练框架相兼容，从而支持多样本的并行训练以及验证工作。

为了去降低基础模型在医学适配过程当中训练成本，本文在 SAM 图像编码器当中引入了 LoRA 来开展参数高效微调工作^[17]。具体来讲，SAM 的主干参数在初始化之后大部分会处于冻结状态，仅仅是在图像编码器的注意力相关线性映射当中去插入低秩适配分支，从而学习面向目标任务的增量表示；同时，掩膜解码器的参数被设定为可训练，以此来增强它对医学图像局部分割模式的适应能力。这样的

设计让模型在保留大规模预训练视觉先验的基础之上，可以凭借较小的训练代价来逐步学习更契合微观图像线状结构特征的表示方式。相比于去对整个 SAM 开展全量微调工作，LoRA 适配方式在显存开销、训练效率以及小样本稳定性方面要更契合本文的任务需求以及实验条件。

在目前的级联框架当中，SAM-LoRA 的关键优势在于能够充分去运用由 LSSeg 所生成的 prompt 信息。不同于传统交互式分割当中由人工来提供点或者框提示的方式，本文当中的 SAM-LoRA 运用的是由粗分割结果自动生成的 mask prompt 以及 box prompt。这当中，mask prompt 被用来向 SAM 提供目标区域的大致形态以及空间位置，而 box prompt 则被用来进一步去约束潜在的目标范围。这种提示输入的方式让 SAM-LoRA 可以在已有结构先验的基础之上，把注意力集中在边界修正以及局部细化工作当中，而不需要再次去完成整体目标定位任务，从而更契合“精细修正模块”的功能定位。

从输出形式来看，SAM-LoRA 模块首先会在较低的分辨率之下来生成分割掩膜 logits，随后再依靠双线性插值开展上采样操作，从而达到与原始输入一致的空间尺寸。在这里保留 logits 形式而不是马上开展 sigmoid 或者阈值化处理工作，主要缘由是为了便于后续去以及 LSSeg 的粗分割结果开展融合工作。鉴于粗分割分支以及精细分割分支在输出层面运用了统一的 logits 表达形式，所以可以更加自然地去构建残差融合或者是线性融合机制，让后续结果的整合过程具备更好的可学习性以及连续性。

需要指出的是，本文当中的 SAM-LoRA 并不是简单地把 SAM 套运用在医学图像之上，而是在任务先验、输入提示以及训练方式这三个层面开展了适配工作。第一点是，输入侧凭借 LSSeg 来自动生成 prompt，从而让模型获得适宜线状结构分割的任务引导；第二点是，参数侧依靠 LoRA 来适配图像编码器并且联合去训练解码器，从而降低了迁移成本；第三点是，输出侧把它当作局部修正分支，而不是去直接替代粗分割模块。正是由于这种面向任务的结构化设计，SAM-LoRA 才可以在本文的级联框架当中更加有效地去发挥对复杂边界以及微细结构的精细分割能力。

3.4 Prompt 构造与优化策略

在基于 SAM 的分割框架当中，prompt 是连接图像信息以及目标分割结果的关键桥梁。SAM 原生模型通常会去依靠人工来提供点、框以及掩膜等提示信息，从而引导模型去对指定的区域开展分割工作^[15]。然而，在医学图像自动化分析场景当中，逐张图像人工去构造 prompt 并不现实，尤其是在批量数据的训练以及自动推

理过程当中，去如何构造稳定、有效并且与任务目标相契合的 prompt，直接决定了基础模型在医学场景当中的可用性。所以，本文围绕着自动 prompt 构造以及 prompt 优化来开展设计，让它能够更好地去服务于线状结构分割任务。

本文所运用的 prompt 主要囊括了 mask prompt 以及 box prompt 这两个类别。在这里面，mask prompt 直接来源于 LSSeg 粗分割模块所输出的初始 logits，它的作用是去为 SAM 提供目标区域的整体形态信息以及空间分布先验。与把粗分割结果开展二值化处理之后当作提示有所不同，本文保留了连续的 logits 形式，并且凭借双线性插值把它开展下采样，从而使其达到与 SAM prompt encoder 相匹配的分辨率。这种方式的优势在于，连续的响应不单能够反映出明确的前景区域，还能够去保留边界附近以及低置信度区域的信息，由此来为 SAM 在后续细化阶段当中去提供更丰富的判别依据。

为了去进一步提高 prompt 对于细小结构的覆盖能力，本文在 mask prompt 构造过程当中引入了 prompt_bias。它的基本思想是在 LSSeg 输出的原始 logits 之上增加一个可调偏置，从而在概率意义上去降低前景判定的门槛，提高疑似目标区域的召回率。针对线状结构分割任务而言，要是过早地去丢弃掉边界模糊或者是响应较弱的细小血管，往往会由后续的精细分割模块失去修正的机会；而适度地去提高 prompt 的召回率，则可以把更多潜在的目标区域去传递给 SAM 来开展进一步判断。这种“高召回优先”的 prompt 构造思想，是本文针对微观图像里细小结构容易出现遗漏问题所选用的重要策略。

除了 mask prompt 之外，本文还设计了 box prompt，用来进一步去约束目标的空间范围。在目前的实现当中，box prompt 可以凭借两种方式来获得：在训练阶段，要是存在着真实标注，就可以由真实掩膜来生成目标包围框，从而去为 SAM 提供更加稳定的空间约束；而在推理阶段，则会根据 LSSeg 粗分割结果来自动生成最小包围框，从而让完全自动化的 prompt 构造流程得以实现。为了去避免提示框因为过于紧凑而遗漏掉细小分支，本文在生成 box prompt 时进一步引入了 box_bias 以及 box_expand_ratio，依靠扩大预测区域的响应以及去扩张包围框的边界，从而提高对于微细血管以及边界区域的包络能力。这一设计会有助于去减少由于局部裁剪过窄所导致的结构截断问题。

在训练以及推理的一致性方面，prompt 构造还面临着一个关键问题，也就是在训练阶段要是长期去依靠真实掩膜来生成 box prompt，而推理阶段却只能运用预测结果来生成 prompt，那就容易导致前后的分布出现不一致，从而影响模型的泛化表现。针对这一问题，本文在训练过程当中设计了基于 epoch 的 prompt curriculum 策略：在训练初期，优先去运用真实标注来生成 prompt，从而加快模型实现稳定收敛；到了中期则会逐步地引入由预测结果所生成的 prompt；而在后期则主要去依靠

预测 prompt，以此让模型逐渐去适应测试阶段的输入分布。借助这种由“强监督提示”向“预测提示”开展平滑过渡的训练方式，可以去缓解训练阶段以及推理阶段 prompt 来源差异过大所带来的适配偏移问题。

从整体上来看，本文的 prompt 构造策略并不是简单地去把粗分割结果当作附加输入，而是围绕着线状结构的任务特性来开展了有针对性的设计。mask prompt 负责去提供目标形态先验，box prompt 负责去提供空间范围的约束，prompt_bias 以及 box_bias 被运用来提高细小结构的召回率，box_expand_ratio 被运用来增强对边缘以及分支区域的覆盖能力，而 prompt curriculum 则被运用来提升训练以及推理过程当中的一致性。依靠上述的设计，SAM-LoRA 分支可以在自动化的条件之下获得更契合医学图像分割需求的提示输入，从而更加有效地去发挥它的精细化分割能力。

3.5 残差融合

在级联分割框架当中，去如何对粗分割结果以及精细分割结果开展有效的融合工作，是决定整体性能表现的重要环节。要是简单地把后端 SAM-LoRA 分支的输出当作最终结果来使用，虽然能够去充分地让基础模型的表达能力得以实现，但也会带来一个明显的风险，也就是前端 LSSeg 已经建立起来的结构稳定性可能会被后续的分支所破坏，从而导致整体分割结果在细小结构以及边界区域出现不稳定甚至退化的表现。针对线状结构分割任务而言，这种风险表现得尤其突出，主要是因为主干血管、细小分支以及边界的连续性本身就比较脆弱，一旦后续的分支在局部的预测当中出现了偏差，整体的结构质量就可能会发生明显的下降。正因如此，本文并没有去运用“由 SAM 直接接管最终输出”的这种融合方式，而是选用以 LSSeg 为主、SAM-LoRA 为修正分支的残差融合策略。

残差融合的核心思想在于，把 LSSeg 的输出视作为整体预测的主干结果，而把 SAM-LoRA 的输出视作为在此基础之上的增量修正量。这样做的好处在于，前端模型已经提取出来的稳定结构不会被轻易地给覆盖掉，后端模型的作用被限制在了“补充以及修正”而并不是“完全重构”之上，由此更加契合本文中“保持基线保底能力、运用基础模型开展局部细化工作”的总体设计目标。从任务角度来看，这种融合方式本质上属于一种功能的分解：LSSeg 负责去提供稳定的主体结构，而 SAM-LoRA 负责去弥补边界模糊、细小分支遗漏以及局部形态不规则等问题，二者在功能层面形成的是互补而并不是替代的关系。

在目前的项目实现当中，残差融合支持两种具体的表现形式。一种是基于可学习系数的线性残差形式，也就是把最终的输出表示为粗分割 logits 以及 SAM 分

支 logits 的加权之和；另一种则是更灵活的卷积融合形式，即先把两路的 logits 在通道维度上开展拼接工作，再依靠 1×1 卷积来学习二者之间的融合关系。不管选用哪种形式，融合的基本原则都是为了去保留 LSSeg 的主导地位，并且让 SAM 的输出以修正量的形式来参与最终结果的生成工作。这样的设计既保留了融合层所具备的可学习性，同时也避免了后端分支在训练初期因为不稳定而对最终输出产生过大的干扰。

为了去进一步提高融合过程当中的稳定性，本文在融合模块开展初始化的时候，选用了偏向于 LSSeg 主分支的参数设置。以目前默认的卷积融合形式为例，如图 3.5 所示，融合头在进行初始化的时候会让 LSSeg 的输出直接通过，而把 SAM 分支的初始权重设定为一个较小的值，即 residual_init_alpha。这便意味着在训练初期的时候，最终的输出会近似等于粗分割结果加上一个比较弱的 SAM 修正项，从而让整个框架具备了“可以退化回 LSSeg 基线”的能力。只有当 SAM 分支在训练过程当中去学习到了确实具备价值的局部修正信息的时候，它的贡献才会依靠融合层来逐渐得到增强。这种初始化的方式可以有效地去降低级联模型在刚开始时因为后端分支不稳定而拖累整体结果的风险。




图 3.5 残差融合结构图

从优化角度来看，残差融合还会有助于改善两个分支在开展协同训练时的梯度传播方式。要是直接去让后端分支独立生成最终预测结果，那么训练过程就会更加倾向于让后端模型来承担全部任务，前端模型所提供的这种结构先验就可能会被弱化，甚至在联合训练当中失去它原有的意义。而在残差融合框架之下，后端分支只需要去学习“相对于粗分割结果来讲还差什么”，学习目标会变得更加明确，同时

也更加契合线状结构任务当中“局部修正优于整体重构”的这种实际需求。这种设计能够在一定程度上去缓解多分支联合训练当中常见的目标竞争问题，从而提高级联模型在整体训练方面的稳定性。

综合来看，残差融合不仅是一个简单的结果整合步骤，它更是本文级联模型设计当中的一项关键稳定机制。它凭借在结构上对 SAM-LoRA 的输出角色开展限制工作，使后端分支从一个“完全替代者”转变成为一位“增量修正者”，从而既保留了 LSSeg 在医学线状结构任务当中的稳定优势，还为 SAM-LoRA 提供了能够去发挥它精细化能力的空间。也正是基于这一设计来开展工作，本文所提出的级联框架才能够在尽量不去牺牲基线性能的前提之下，去探索基础模型在局部边界以及细小结构修正方面的潜在收益。

3.6 模型训练策略

为了能够让由 LSSeg 以及 SAM-LoRA 来构成的级联模型实现稳定收敛，并且去充分地发挥专用分割网络以及基础模型适配分支各自所具备的优势，本文在开展训练的过程当中选用了有针对性的优化策略。整体层面上，训练流程会去把 AdamW 当作优化器来使用，把 StepLR 当作学习率调度方式来开展工作，并且把混合精度训练结合起来从而去提高训练方面的效率。在此基础之上，鉴于级联模型不同组成部分所具备的特性，进一步去设计了分层学习率、LoRA 参数配置、超参数搜索以及 prompt curriculum 等训练机制，从而提高模型的可训练性以及实验结果的可靠程度。

首先，在开展优化器设计的方面，本文并没有去对整个级联模型选用统一的学习率，而是根据不同模块的功能以及训练状态来开展分层学习率的设置工作。在目前的项目实现当中，当 LSSeg 参与到联合训练当中的时候，它的参数会去运用相对较小的学习率，也就是把主学习率去乘以 `lsseg_lr_ratio`；而 SAM-LoRA 的图像编码器里可训练的 LoRA 参数、prompt encoder、mask decoder 以及融合模块的参数，则会去运用主学习率来开展更新工作。这一策略的基本缘由是：LSSeg 在前期的时候已经具备了较强的线状结构建模能力，把它当作粗分割先验并不适宜被过快地去扰动；而后端 SAM-LoRA 分支以及融合层作为新引入或者是需要去进一步开展适配的部分，就需要有更加充分的参数更新空间。依靠这种差异化的学习率设置，可以在保持粗分割稳定性的同时，去提高后端精细分割模块的适配效率。

其次，在开展 SAM 适配参数设置的方面，本文会选用 LoRA 来开展参数高效微调工作，并且把 LoRA 的秩值 `lora_r` 当作重要的训练参数之一。在当前的实验配置当中，LoRA 的秩值通常会被固定为一个较小的常数，以此来降低搜索空间

并优先去观察级联机制本身所带来的收益；而 LoRA 的缩放参数 `lora_alpha` 则会依据预设的比例由 `lora_r` 开展派生。与此同时，把掩膜解码器参数保持在可训练的状态，可以让模型在大规模预训练视觉先验的基础之上，去进一步学习更加适宜微观图像线状结构的局部分割模式。这样的参数设置兼顾了训练资源的约束以及模型的适配能力，同时也契合本文中“在有限成本之下来引入基础模型能力”的这种目标。

在开展超参数优化的方面，本文会运用 Optuna 来对级联模型当中的关键参数开展自动搜索工作。目前的实现当中，搜索过程是围绕着外层交叉验证里的训练集来开展的，在每一个外层 fold 内部去划分子训练集以及验证集，从而用来寻找该 fold 之下最优的参数配置。相比于去对所有的训练参数开展大范围的盲目搜索，本文把搜索的重点集中在了对级联效果影响比较大的参数之上，比如学习率 `lr`、粗分割分支学习率比例 `lsseg_lr_ratio`、`prompt_bias`、`residual_init_alpha`、`box_bias`、`box_expand_ratio` 以及 `prompt curriculum` 相关的参数等。依靠这种聚焦式的搜索策略，可以在有限的训练预算之下去更高效地识别出影响级联性能的关键因素，从而提高实验调优的针对性以及可解释性。

在 `prompt` 训练机制的方面，本文进一步去设计了 `prompt curriculum`，用来缓解训练阶段以及推理阶段 `prompt` 来源不一致的问题。具体来讲，在训练初期的时候，模型会主要去运用由真实标注所生成的 `prompt`，以此来帮助后端 SAM-LoRA 分支更快地去建立起稳定的映射关系；在中间阶段的时候，真实 `prompt` 以及预测 `prompt` 会以一定的概率被混合使用，从而让模型逐渐地去适应由粗分割结果所生成的提示分布；在训练后期，则会完全去依靠预测 `prompt`，从而让模型最终面向测试阶段的真实使用场景来开展优化工作。在目前的实现当中，该过程是凭借 `gt_prompt_warmup_epochs` 以及 `predicted_prompt_only_after` 这两个参数来开展控制的，从而让从 `gt` 也就是真实标注，到 `mixed` 即混合模式，再到 `pred` 也就是预测提示的平滑过渡得以实现。与固定地选用单一的 `prompt` 来源相比，这种课程式的训练策略会更有利于去提高模型在自动推理条件之下的稳定性以及泛化能力。

此外，本文在开展训练的过程当中还运用了若干常规但是很有必要的工程化策略，从而保障实验可以顺利地进行。比如，去选用自动混合精度训练也就是 AMP，从而降低显存占用并加快迭代速度；借助梯度缩放器来提高半精度训练时的数值稳定性；运用学习率调度器来按固定的步长衰减学习率，以此来改善训练后期的收敛效果；在开展交叉验证以及参数搜索的过程当中，依靠去清理显存缓存以及回收中间对象，从而减轻多轮实验所带来的资源压力。这些实现细节虽然并不会去直接改变模型的结构，但是针对级联模型的大量实验以及参数对比工作来讲，具备着重要的支撑作用。

总体来看，本文的模型训练策略并不是简单地去套用通用的训练流程，而是围绕着级联架构当中“前端稳定、后端适配、提示逐步过渡”的这些特性来开展设计的。分层学习率保证了 LSSeg 主干不会被过度地破坏，LoRA 参数设置降低了大模型适配的成本，Optuna 搜索提高了关键超参数寻优方面的效率，而 prompt curriculum 则缓解了训练以及推理阶段提示来源不一致的问题。上述的这些策略共同构成了本文级联模型能够开展有效训练以及稳定优化的重要基础。

第 4 章 实验结果与分析

4.1 实验环境与数据集

本文所有的实验均是鉴于当前项目代码来开展实现工作的,选用 PyTorch 深度学习框架去完成模型训练以及推理工作,在训练流程当中把 MONAI 指标计算、Albumentations 数据增强以及 Optuna 超参数搜索工具结合起来,从而去构建起完整的实验管线。模型训练阶段会去运用 AdamW 优化器以及 StepLR 学习率调度策略,并且会去开启自动混合精度训练,以此来实现计算效率的提高。除开特别说明的情况,实验当中的图像会统一开展缩放工作到 512×512 ,外层会去选用 5 折交叉验证,训练轮数设定为了 70, Optuna 搜索次数是 40,级联模型默认会把 DiceCE 当作损失函数来开展使用。

本文实验主要是围绕着微观图像当中的线状结构分割任务来开展的,选取了多个具备代表性的公开数据集来开展验证工作。其中, STARE、RITE、CHASE_DB1 以及 HRF 属于典型的视网膜血管分割数据集,分别包含了 19、39、27 以及 44 组图像以及标注;而 AxonDeepSeg_SEM 则被用来评估方法在其他微观线状结构场景当中的适用性,总共包含了 9 组样本。上述的数据集在目标尺度、图像质量、背景复杂度以及结构形态方面都存在着差异,能够较为全面地去检验模型在不同微观图像场景之下的泛化能力以及稳定性。

在开展实验划分方式的方面,本文选用了统一的交叉验证流程,以此来保证不同模型对比工作方面的公平性。针对每一个数据集,首先会依靠外层的 KFold 把数据划分为训练集以及测试集;随后在训练阶段把 Optuna 结合起来去对关键的超参数开展搜索工作,并且在当前 fold 之下的最佳参数之上重新开展模型训练工作,最终在对应的测试集上开展评价并且记录下指标。实验结果会同时去保存各个 fold 的指标以及整体聚合之后的结果,从而能够去从均值以及标准差这两个层面来分析模型的表现。

其中, STARE 数据集是视网膜血管分割研究当中运用得比较广泛的公开数据集之一,图像来源于真实的眼底检查场景,包含了较为明显的病理变化、光照不均以及局部低对比区域。该数据集当中的血管粗细差异比较大,部分细小血管以及背景之间的灰度差异并不明显,所以对模型的细小结构识别能力以及抗干扰能力提出了比较高的要求。针对本文方法而言, STARE 会更适宜用来检验级联模型在复杂背景以及细小分支恢复方面的表现。

RITE 数据集的特性在于图像数量相对更多，血管分布比较复杂，并且存在着主干血管以及微细分支同时出现的情况。与部分仅仅关注主干结构的任务有所不同，RITE 对于模型在整体结构保持以及局部细节恢复之间的平衡能力要求会更高，所以很适宜当作验证模型稳定性和连续性表现的重要数据集。

CHASE_DB1 数据集采集自儿童眼底图像，受到拍摄条件、眼底区域大小以及个体差异的影响，图像当中的血管走向以及背景分布具备一定的变化。该数据集当中的血管往往比较细，局部区域的对比度比较低，并且部分图像当中存在着较为复杂的交叉以及分叉结构，所以对模型的局部边界刻画能力以及拓扑保持能力具备着较强的挑战性。本文在该数据集之上的实验主要被运用来分析方法对于细小血管以及复杂分支区域的适应能力。

HRF 数据集具备着较高的图像分辨率，能够去提供更加丰富的血管纹理以及边界细节，所以常被用来评估模型在高分辨率场景之下的血管分割性能。与此同时，更高的分辨率也带来了更大的尺度变化以及更复杂的背景细节，使得模型不仅需要去正确提取主干血管，还应当较大的图像范围之内去维持细小结构的连通性以及边界的一致性。针对本文所提出的级联方法，HRF 更适宜用来观察在基线模型已经比较稳定的前提之下，后端精细分支能够带来的增量修正效果。

除了典型的视网膜血管数据集之外，本文还引入了 AxonDeepSeg_SEM 数据集，以此来验证方法在非眼底线状结构任务当中的可迁移性。该数据集来源于扫描电子显微镜图像，目标结构以及眼底血管在成像纹理、背景分布以及局部形态上存在着明显的差异，更加接近于一般的微观生物结构分割场景。把该数据集纳入到实验当中，会有助于去评估本文方法是否仅仅对视网膜血管任务有效，还是对更广义的微观线状结构分割也同样具备着适用性。

在开展模型对比设置的方面，本文第四章会重点关注所提出的 LSSegSAMLoRA 与单独的 LSSeg 基线之间的差异，也就是在相同的任务背景之下比较“专用线状结构分割模型”以及“专用模型 + 基础模型细化分支”的性能变化情况。为了保证分析工作的聚焦，后续的结果仅会鉴于以下五组配对实验日志来开展：STARE、RITE、CHASE_DB1、HRF 以及 AxonDeepSeg_SEM 上的 LSSeg 以及 LSSegSAMLoRA 对比结果。

4.2 评价指标

为了能够全面地开展不同模型在微观图像线状结构分割任务当中的性能评价工作，本文会从区域重叠、结构保持以及边界误差这三个维度来选取多种评价指标，从而开展综合性的分析工作。区域类的指标主要囊括了 AP、DSC 以及 mIoU 这

几项。在这里面，AP 被用来开展模型在不同判定阈值之下对前景目标的综合检测能力的衡量工作；而 DSC 以及 mIoU 则被用来反映预测区域以及真实标注之间的重叠程度，它们是医学图像分割当中最常会去选用的基础指标。

考虑到本文的研究对象主要为血管、轴突以及类似的线状结构，要是仅仅去依靠区域类的指标，并不足以去全面地反映分割的质量，所以还引入了 clDice 来开展对结构连通性以及拓扑保持能力的评价工作。针对这类目标来讲，即便区域的重叠程度比较高，要是分支断裂得很严重或者是主干的连通性不足，那就依然很难去满足实际的分析需求。由此可见，clDice 对于本文方法所开展的评价工作具备着重要的意义。

此外，本文还会去运用边界类指标 ASSD 以及 95HD，从而来开展对模型轮廓误差的评价工作。在这里面，ASSD 被用来反映预测边界以及真实边界之间的平均几何距离，而 95HD 则被用来开展对较为稳健的最大边界偏差的衡量工作。这两项指标数值越小，就说明模型在目标轮廓定位方面表现得越发精确。针对视网膜血管之类的细长目标而言，边界的质量往往会直接地去影响到宽度测量以及形态分析工作，所以边界类的指标也同样是不可以去忽视的。

最后，本文还会去统计 ODS 来当作综合分割表现的辅助指标，并且去记录 MSE，从而来反映像素级别的误差。总体来看，本文在开展结果分析的过程当中会遵循以下的原则：针对 AP、DSC、mIoU、clDice 以及 ODS 而言，数值越大就表示模型的性能表现越好；针对 MSE、ASSD 以及 95HD 而言，数值越小就表示模型的误差越小。凭借多指标的联合分析工作，可以更加客观地去对不同模型在区域、结构以及边界层面的真实表现开展评价。

4.3 对比实验

为了验证本文所提出 LSSegSAMLoRA 级联模型相较单独 LSSeg 基线的改进效果，本文分别在 STARE、RITE、CHASE_DB1、HRF 以及 AxonDeepSeg_SEM 数据集上进行成对对比实验。表中结果均来自自己选定实验日志的 5 折交叉验证平均值。

表 1 STARE 数据集对比结果

模型	AP	DSC	MIoU	CLDICE	ASSD	95HD	ODS
LSSeg	0.815	0.785	0.647	0.812	1.798	13.928	0.788
LSSegSAMLoRA	0.843	0.808	0.679	0.831	1.389	9.944	0.812

表 2 RITE 数据集对比结果

模型	AP	DSC	MIOU	CLDICE	ASSD	95HD	ODS
LSSeg	0.835	0.799	0.667	0.801	1.504	12.808	0.803
LSSegSAMLoRA	0.840	0.805	0.674	0.807	1.391	11.942	0.808

表 3 CHASE_DB1 数据集对比结果

模型	AP	DSC	MIOU	CLDICE	ASSD	95HD	ODS
LSSeg	0.792	0.774	0.633	0.779	2.031	17.018	0.777
LSSegSAMLoRA	0.807	0.795	0.660	0.799	1.568	12.899	0.797

表 4 HRF 数据集对比结果

模型	AP	DSC	MIOU	CLDICE	ASSD	95HD	ODS
LSSeg	0.814	0.784	0.646	0.782	0.910	8.012	0.788
LSSegSAMLoRA	0.817	0.786	0.649	0.785	0.896	7.953	0.791

表 5 AxonDeepSeg_SEM 数据集对比结果

模型	AP	DSC	MIOU	CLDICE	ASSD	95HD	ODS
LSSeg	0.830	0.778	0.637	0.817	0.947	4.233	0.785
LSSegSAMLoRA	0.831	0.785	0.647	0.825	0.925	4.152	0.788

从整体结果来看，在本文所选定的五组对比实验当中，LSSegSAMLoRA 在所有数据集上均表现得优于单独的 LSSeg 基线，这说明级联框架在目前的实验设置之下总体上是有效的。在这里面，STARE 以及 CHASE_DB1 上的提升较明显，RITE 以及 AxonDeepSeg_SEM 之上实现了稳定的小幅提高，而 HRF 之上的提升则表现得相对有限。

4.4 结果分析

把各个数据集之上的实验结果结合在一起来开展性能分析的话，能观察到 LSSegSAMLoRA 在这五个数据集上都实现了相较于单独 LSSeg 的非负增长。这一情况说明了在已经拥有线状结构专用模型的基础之上，再把 SAM-LoRA 细化分支引入进来，大多数时候是可以对粗分割结果去形成有效补充的。而且这种提高不仅仅只是反映在 DSC 以及 mIoU 这类区域指标之上，同时在 clDice 还有 ASSD 这些结构以及边界指标方面也表现出了改进作用。这也就说明了所提出的方法不单单是在区域重叠层面去产生变化，它对于结构连通性以及边界定位质量同样也是有

好处的。

具体到不同的数据集来看，STARE 以及 CHASE_DB1 这里的收益会显得格外明显，具体的 AP、DSC 等各项数据都有了不同程度的增长。这便表明在类似的环境里，SAM-LoRA 分支能较好地凭借 LSSeg 提供的先验信息，来对局部边界以及细小结构开展修正工作。与此同时，级联模型在 RITE 或者是 AxonDeepSeg_SEM 上也表现出了虽然幅度不算大、但却非常平稳的改进趋势，体现出了一种比较好的跨任务适应性。到了 HRF 数据集这边，提升幅度就表现得最为微小，这说明了要是粗分割基线本身就已经非常稳固，后端分支能起到的改进空间就会受到一定程度的限制。

至于指标类型的变化，会发现该方法的收益主要集中在区域级分割质量的提高，以及结构连通性的维持上。这也正契合了由 LSSeg 负责提供稳定粗分割、由 SAM-LoRA 针对微细结构来开展增量式细化这一设计目标，让它更适宜被理解成一种“鉴于先验来开展工作的精细修正框架”。凭借图中给出的预测结果对比，可以更直观地去看到级联模型对局部细节所产生的修正效果。




图 4.1 STARE




图 4.2 RITE




图 4.3 HRF




图 4.4 CHASE_DB1




图 4.5 AxonDeepSeg_SEM

第五章 总结

本文针对微观生物医学图像中线状结构分割任务中存在的细小结构易遗漏、边界模糊区域难刻画以及拓扑连续性保持不足等问题，提出了基于 LSSeg 与 SAM-LoRA 的级联分割方法，并围绕其结构设计、训练策略和实验表现进行了系统研究。与前文侧重理论基础和方法设计的章节不同，本章重点从算法结果出发，对本文方法的实际优势、适用范围和现阶段局限进行总结。

从整体的实验结果方面来看，本文的方法在 STARE、RITE 以及 CHASE_DB1 等五个数据集之上，全都去实现了相较于单独 LSSeg 基线的非负提升。这一情况也就体现出在专用线状结构分割模型之后，再去运用经过低秩适配的基础模型细化分支，在多数情况下是可以去形成有效补充的。尤其是在 STARE 以及 CHASE_DB1 这类数据集里，该方法在 AP、DSC 以及各类边界指标上都取得了挺明显的改进，这表明级联框架对于复杂背景或者细小血管这些区域拥有着比较好的修正能力。即便是到了 HRF 数据集这边，由于基线结果本身就比较强，模型也依然是获得了一定的小幅增益，这也就证明了级联策略还是拥有着增量修正作用的。

把定量的指标以及定性的可视化结果结合起来开展分析的话，就能进一步去总结出本文方法的优势。表现得比较突出的改进体现在对细小分支以及弱响应区域的恢复能力上面，比如在 STARE 等数据集中，LSSegSAMLORA 往往能够去把部分容易中断的细结构给补全。同时，本文方法在开展主干结构的稳定保持工作时，也对局部边界拥有着更好的修正能力。实验里 ASSD 等数值的整体下降，其实也就说明了该方法在边界定位方面是具备优势的。另一方面，本文方法并不是完全去依靠后端基础模型来重新生成结果，而是把 LSSeg 的粗分割结果当作主干，依靠残差融合的方式来开展增量修正工作，从而可以去避免后端分支直接替代基线模型所带来的不稳定性。

即便如此，本文的方法依然还是存在着一些比较明显的局限性。实验表明不同数据集之上的增益幅度差异挺大的，这也就说明该方法对于数据分布以及图像质量表现得比较敏感。特别是在 HRF 这种基线已经很强的场景里，后端细化分支能提供的增益就表现得比较有限了。同时，目前的方法对于 prompt 的质量也依然存在着依赖。虽然本文通过 prompt_bias 以及提示渐进式训练策略来开展了优化工作，但要是粗分割结果出现了较大偏差，后续能发挥的作用就会受到限制。此外，现在的融合方式也还是显得比较简单，在表达能力方面会受到一些限制，还不足以去根据不同区域的难度来自动开展依赖程度的调节工作。

鉴于上述的结果以及局限，后续的研究工作依然还有着比较大的优化余地。自动 prompt 的构造质量可以继续去提高，比如把不确定性估计或者是骨架先验给结合起来，让后端细化分支获得更可靠的提示。融合机制也能进一步增强，从而去动态地调节粗分割以及细化分支的贡献比例。

总体上来看，本文的实验结果体现出基于 LSSeg 与 SAM-LoRA 的级联分割方法在不破坏基线稳定性的前提之下，对细小结构恢复以及边界修正是有着积极作用的。同时这也反映出，基础模型在医学场景当中的有效运用，并不在于去简单地替代专用模型，而更适宜把任务先验作为基础，凭借参数高效微调以及结构化级联的方式，去发挥它的精细化能力。

谢 辞

时光荏苒，至此毕业论文的撰写工作即将去完成，本科阶段的学习以及生活也即将画上句号。在开展选题、研究、实验以及写作的整个过程当中，得到了许多来自老师、同学还有家人的关心以及支持。在论文得以完成之际，衷心地向所有给予了指导以及帮助的人来表示感谢。

尤其要感谢的是指导教师赵爱特，在开展论文撰写的整个过程当中，老师都给予了耐心细致的指导。无论是前期去把研究方向确定下来，还是后期开展内容的修改，老师都提出了许多宝贵的意见，从而让论文内容的完善得以实现。老师严谨的治学态度以及对学术问题的深层次思考，也让人在这个过程当中受益匪浅。与此同时，学院各位任课老师在本科阶段所开展的悉心培养同样非常关键。正是在专业课程学习当中，才得以去掌握计算机科学相关的理论知识，并依靠实践训练来提升分析问题以及解决问题的能力，这些方面的积累为本文的完成去奠定了坚实的基础。

此外，那些在论文研究过程当中给予了帮助的同学以及朋友也同样值得感谢。大家在开展模型训练以及实验调试的时候，都给予了许多支持以及建议。除了同学之外，家人一直以来所给予的理解以及支持也必不可少。在开展学习以及生活的过程中，家人始终给予了充分的包容，要是没有他们的鼓励，那就很难顺利地去完成本科阶段的学习任务。

最后要说的是，毕业论文的完成不仅是对学习成果的一次总结，也会是未来努力前行的一个新起点。在今后的学习以及工作当中，会继续去保持认真踏实的态度，并以实际行动去回馈老师、家人以及所有关心并帮助过的人。

参考文献

- [1]. ZHAO A, LI J. A significantly enhanced neural network for handwriting assessment in Parkinson's disease detection[J]. Multimedia Tools and Applications, 2023, 82(25): 38297-38317.
- [2]. ZHAO A, WU H, CHEN M, et al. A spatio-temporal Siamese neural network for multimodal handwriting abnormality screening of Parkinson's disease[J]. International Journal of Intelligent Systems, 2023, 2023: 9921809.
- [3]. WANG N, NIU X, YUAN Y, et al. A coordinate attention enhanced Swin Transformer for handwriting recognition of Parkinson's disease[J]. IET Image Processing, 2023, 17(9): 2686-2697.
- [4]. ZHAO A, WANG N, NIU X, et al. A triplet multimodal transfer learning network for speech disorder screening of Parkinson's disease[J]. International Journal of Intelligent Systems, 2024, 2024: 8890592.
- [5]. ZHAO A, LI J. Two-channel LSTM for severity rating of Parkinson's disease using 3D trajectory of hand motion[J]. Multimedia Tools and Applications, 2022, 81(23): 33851-33866.
- [6]. ZHAO A, LIU Y, YU X, et al. Artificial intelligence-enabled detection and assessment of Parkinson's disease using multimodal data: A survey[J]. Information Fusion, 2025, 121: 103175.
- [7]. LONG J, SHELHAMER E, DARRELL T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Boston: IEEE, 2015: 3431-3440.
- [8]. RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional networks for biomedical image segmentation[C]//Medical Image Computing and Computer-Assisted Intervention - MICCAI 2015. Cham: Springer, 2015: 234-241.
- [9]. CHEN L C, PAPANDREOU G, KOKKINOS I, et al. DeepLab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected CRFs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 40(4): 834-848.
- [10]. ISENSEE F, JAEGER P F, KOHL S A A, et al. nnU-Net: A self-configuring method for deep learning-based biomedical image segmentation[J]. Nature Methods,

- 2021, 18(2): 203-211.
- [11]. OKTAY O, SCHLEMPER J, LE FOLGOC L, et al. Attention U-Net: Learning where to look for the pancreas[EB/OL]. arXiv, 2018[2026-04-29]. <https://arxiv.org/abs/1804.03999>.
 - [12]. HATAMIZADEH A, TANG Y, NATH V, et al. UNETR: Transformers for 3D medical image segmentation[C]//2022 IEEE/CVF Winter Conference on Applications of Computer Vision. Waikoloa: IEEE, 2022: 1748-1758.
 - [13]. CHEN J, MEI J, LI X, et al. TransUNet: Rethinking the U-Net architecture design for medical image segmentation through the lens of transformers[J]. Medical Image Analysis, 2024, 97: 103280.
 - [14]. CAO H, WANG Y, CHEN J, et al. Swin-Unet: Unet-like pure transformer for medical image segmentation[EB/OL]. arXiv, 2021[2026-04-29].
 - [15]. KIRILLOV A, MINTUN E, RAVI N, et al. Segment Anything[EB/OL]. arXiv, 2023[2026-04-29].
 - [16]. HUANG Y, YANG X, LIU L, et al. Segment anything model for medical images?[J]. Medical Image Analysis, 2024, 92: 103061.
 - [17]. ZHANG K, LIU D. Customized Segment Anything Model for medical image segmentation[EB/OL]. arXiv, 2023[2026-04-29].
 - [18]. WU J, WANG Z, HONG M, et al. Medical SAM Adapter: Adapting Segment Anything Model for medical image segmentation[J]. Medical Image Analysis, 2025, 102: 103547.
 - [19]. SHIT S, PAETZOLD J C, SEKUBOYINA A, et al. clDice: A novel topology-preserving loss function for tubular structure segmentation[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Nashville: IEEE, 2021: 16555-16564.
 - [20]. KHANDOUZI A, ARIAFAR A, MASHAYEKHPOUR Z, et al. Retinal vessel segmentation, a review of classic and deep methods[J]. Annals of Biomedical Engineering, 2022, 50(10): 1292-1314.
 - [21]. WANG D, HAYTHAM A, POTTENBURGH J, et al. Hard Attention Net for automatic retinal vessel segmentation[J]. IEEE Journal of Biomedical and Health Informatics, 2020, 24(12): 3384-3396.
 - [22]. CHENG Y L, MA M N, ZHANG L J, et al. Retinal blood vessel segmentation based on densely connected U-Net[J]. Mathematical Biosciences and Engineering, 2020, 17(4): 3088-3108.

- [23]. DU H, ZHANG X, SONG G, et al. Retinal blood vessel segmentation by using the MS-LSDNet network and geometric skeleton reconnection method[J]. Computers in Biology and Medicine, 2023, 153: 106416.
- [24]. OUYANG J, LIU S, PENG H, et al. LEA U-Net: A U-Net-based deep learning framework with local feature enhancement and attention for retinal vessel segmentation[J]. Complex & Intelligent Systems, 2023, 9(6): 6753-6766.
- [25]. DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[EB/OL]. arXiv, 2020[2026-04-29].
- [26]. HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[EB/OL]. arXiv, 2021[2026-04-29].
- [27]. RAJITHA K V, PRASAD K, YEGNESWARAN P P. Segmentation and classification approaches of clinically relevant curvilinear structures: A review[J]. Journal of Medical Systems, 2023, 47(1): 40.
- [28]. 张文豪, 瞿绍军, 颜美丽. 基于深度学习的视网膜血管分割研究进展[J]. 计算机应用研究, 2025, 42(5): 1299-1311.